MACHINE LEARNING – L'ALGORITHME KNN

NIVEAU D'ÉTUDE : LGLSI3

FACULTÉ DES SCIENCES DE MONASTIR

RÉALISÉ PAR :

MANAR BEN YAHYA, FEDIA CHAABANE ET IKHLAS BAHIA

PLAN

1. Rappel
2. Définition de KNN
3. Fonctionnement de KNN
4. Choix de paramètre K
5. Avantages et inconvénients
6. Conclusion
7. Exercices d'application

Le Machine Learning

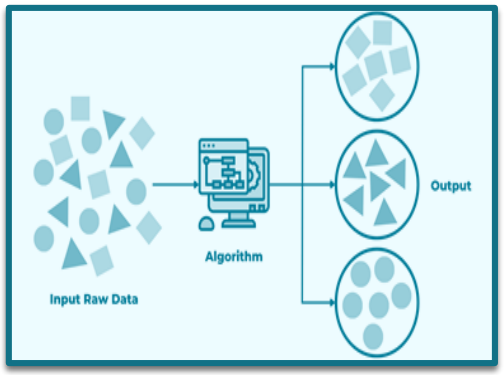
1. Définition:

Le machine learning (ou "apprentissage automatique") est une technologie qui permet à des **ordinateurs d'apprendre par eux-mêmes à partir d'exemples**, sans être explicitement programmés pour chaque tâche

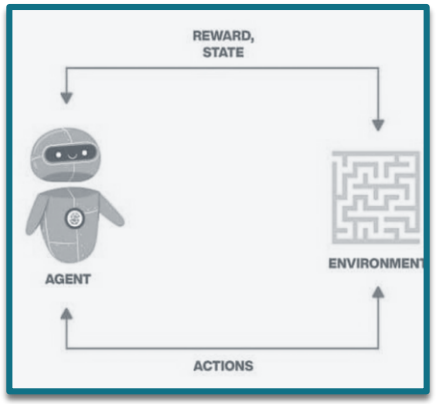
2. Les types d'apprentissage automatique:



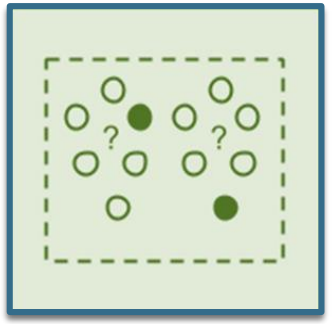
Apprentissage supervisé



Apprentissage non supervisé



Apprentissage par renforcement



Apprentissage semi-supervisé



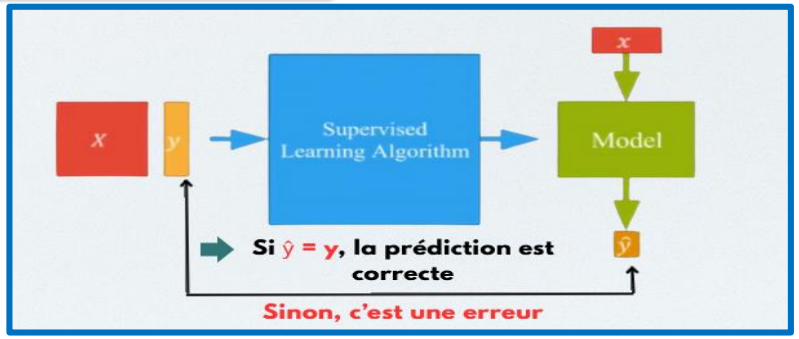
Apprentissage par transfert

RAPPEL

L'apprentissage supervisé

I. Définition:

- **L'apprentissage supervisé** est un type d'apprentissage automatique où un modèle est entraîné sur des données **étiquetées.**

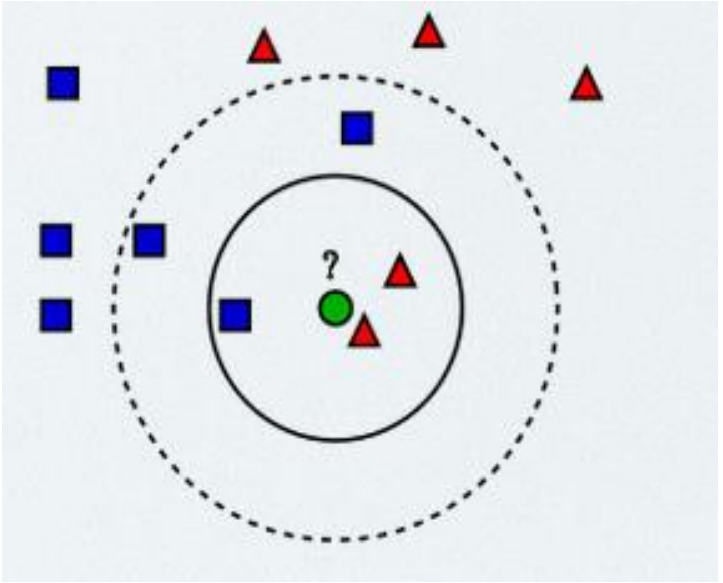


Classification	Régression
y prend des valeurs discrètes	y prend des valeurs continues
Les valeurs possibles seront des classes (chien ou chat).	les valeurs possibles sont des nombres réels (des degrés de température).
Exemples d'algorithmes : Arbres de décision , KNN…	Exemples d'algorithmes : Régression linéaire, régression logistique ,KNN…

RAPPEL

DÉFINITION DE KNN

- **Le KNN (K-Nearest Neighbors) est un algorithme de Machine Learning supervisé qui classe un nouvel élément en regardant les k voisins les plus proches dans les données déjà connues.**
- **Il décide selon la majorité de ses voisins.**



Les caractéristiques de l'algorithme KNN



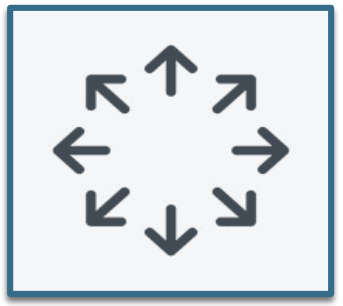
Simple

à comprendre et à utiliser.



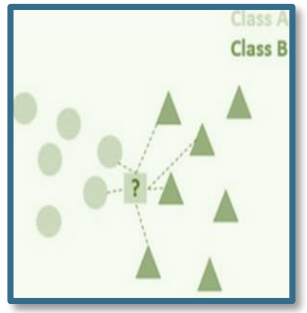
c'est un algorithme paresseux "lazy algorithm":

Il ne "construit" pas de modèle. Il se contente de mémoriser les données et fait les calculs au moment de la prédiction.



Polyvalent

peut être utilisé pour la classification ou la régression.



Se base sur la similarité

DÉFINITION DE KNN

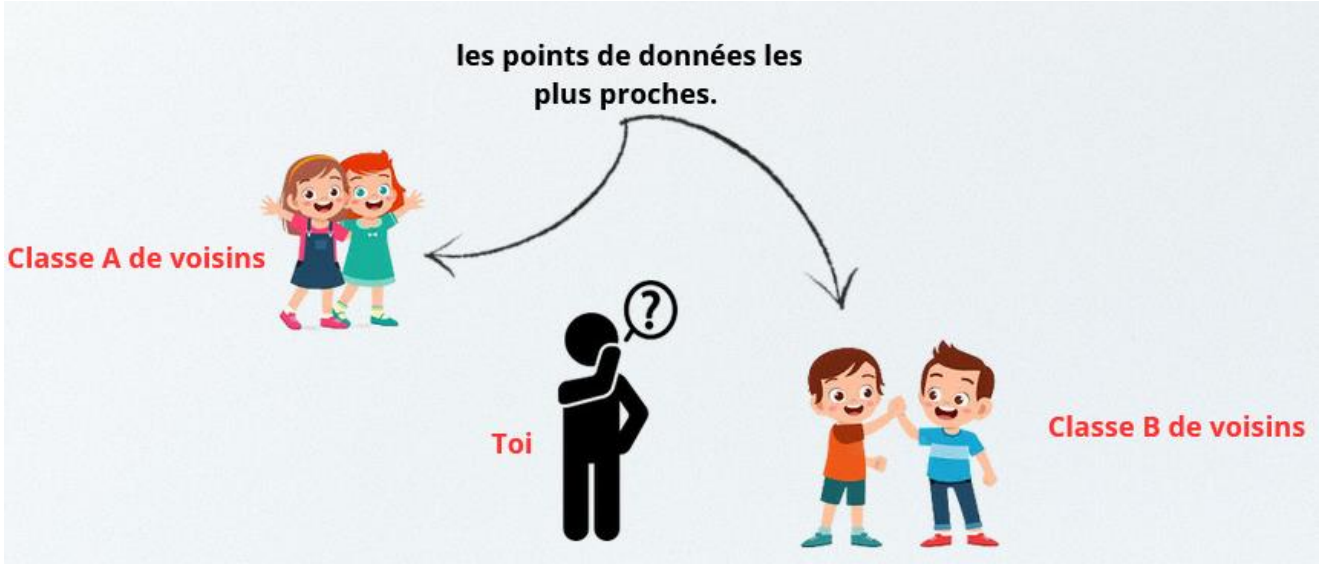
Domaines d’application



DÉFINITION DE KNN

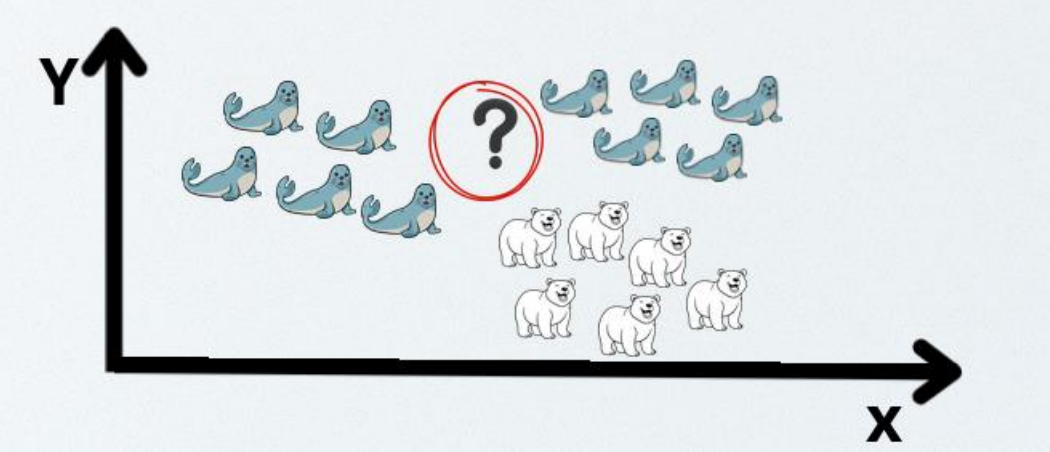
LE PRINCIPE DE KNN

« Dis-moi qui sont tes voisins, je te dis qui tu es ? »



FONCTIONNEMENT DE KNN

- **Notre jeu de données contient des ours et des phoques, chacun est déjà étiqueté "Ours" ou "Phoque".**



⇨ **Un nouvel animal non étiqueté est découvert.**

FONCTIONNEMENT DE KNN

Etape 1:

- **Cette étape consiste à définir la valeur de la variable K (Le nombre de voisins que l'algorithme va consulter pour prendre sa décision).**

⇨ **Prenons K=3.**

Etape 2 :

- **Cette étape consiste à calculer les distances entre la nouvelle donnée et toutes celles déjà existantes.**
- **Utilité : Ces distances permettent à l'algorithme de repérer les plus proches voisins de la nouvelle donnée pour faire sa prédiction.**

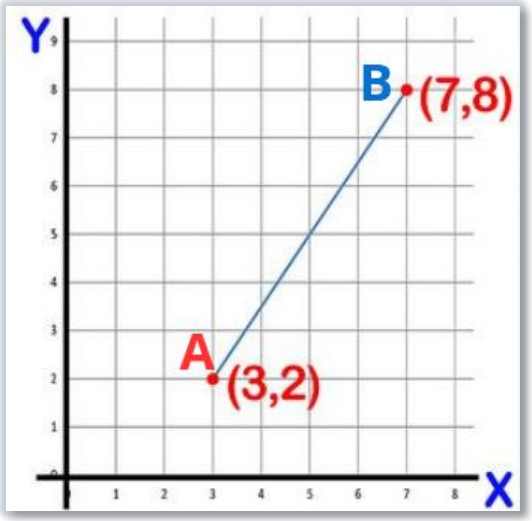
I. Distance Euclidienne

Formule Générale:

Etant donnés deux points
$A(x_A ; y_A)$ et $B(x_B ; y_B)$,
la distance entre les points A et B, c'est-a-dire la longueur du segment [AB] est :

$$AB = \sqrt{(x_B - x_A)^2 + (y_B - y_A)^2}$$

Exemple:



$$AB = \sqrt{[(7 - 3)^2 + (8 - 2)^2]} = 2\sqrt{13}$$

FONCTIONNEMENT DE KNN

2. Distance de Manhattan

Formule Générale:

$$d(A, B) = |X_2 - X_1| + |Y_2 - Y_1$$

- **Exemple:**

calculer la distance entre les points A(2, 3), B(5, 7) en utilisant la formule de Manhattan :

- **Solution:**

$$d(A, B) = |5 - 2| + |7 - 3| = 3 + 4 = 7$$



- D'autres méthodes de calcul de distance existent pour le KNN au-delà de celles citées ici.

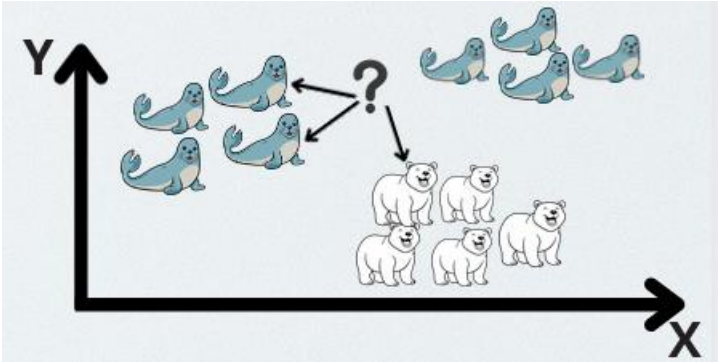
Exemple: Distance de Minkowski, Distance de Hamming...

- Le choix de la méthode de calcul de distance dans l'algorithme k-NN dépend du type de données (numériques, catégorielles, avec ou sans échelle).

FONCTIONNEMENT DE KNN

FONCTIONNEMENT DE KNN

⇨ **Appliqué à notre cas, le calcul des distances évalue l'éloignement du nouvel animal par rapport aux ours et phoques de référence.**



Etape 3:

- **Une fois les distances calculées, on identifie les K plus proches voisins pour classer la nouvelle donnée.**

  ⇨ **Le résultat final est simplement la classe qui apparait la plus fréquemment parmi les K voisins sélectionnés.**

- **Donc, parmi les K=3 plus proches voisins (2 phoques et 1 ours), le nouvel animal est classé phoque par majorité .**

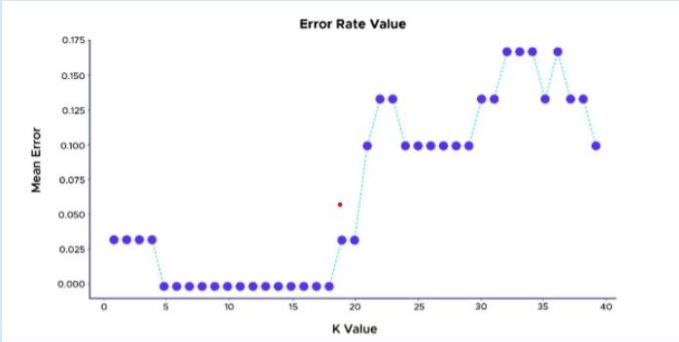
Choisir K n'est pas aléatoire

- Le choix du paramètre k peut conduire à deux situations problématiques:

Sur-apprentissage (Overfitting)	Sous-apprentissage (Underfitting)
• K **très petite** (exemple : k=1). • Le modèle se concentre trop sur **les détails** et perd **les généralités**. ➡ Il mémorise le bruit et les particularités au lieu d'apprendre les tendances générales.	• K **très grande**. • Le modèle **perd les détails** et les motifs importants. ➡ Il est trop simpliste pour capturer la structure complexe des données.

CHOIX DE PARAMÈTRE K

Choisir K n'est pas aléatoire

Validation croisée	Courbe d'erreur
 • La meilleur valeur de K est celle ou l'erreur est plus petite.	**Principe:** Trouver le K optimal en testant chaque valeur sur différentes partitions des données et retenir celle avec la meilleure performance moyenne.



D'autres méthodes existent pour déterminer K (comme le coude, les règles empiriques…)

CHOIX DE PARAMÈTRE K

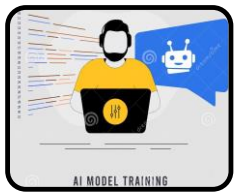
AVANTAGES ET INCONVÉNIENTS

Avantages



Simplicité et Facilité de Compréhension

Le concept est intuitif : "les objets similaires sont proches".



Aucune Phase d'Entraînement Explicite

- il n'y a pas de processus d'entraînement coûteux pour construire un modèle



Adaptabilité aux Données

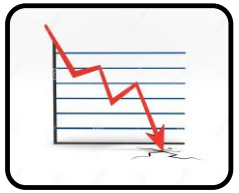
- Il suffit d'ajouter les nouveaux exemples à l'ensemble d'entraînement pour que l'algorithme les prenne immédiatement en compte.

Inconvénients



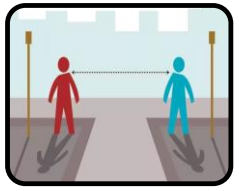
Coût Calculatoire Élevé lors de la Prédiction

l'algorithme doit calculer la distance entre le nouvel exemple et **tous** les points de l'ensemble d'entraînement



Sensibilité au Bruit et aux Données Non Pertinentes

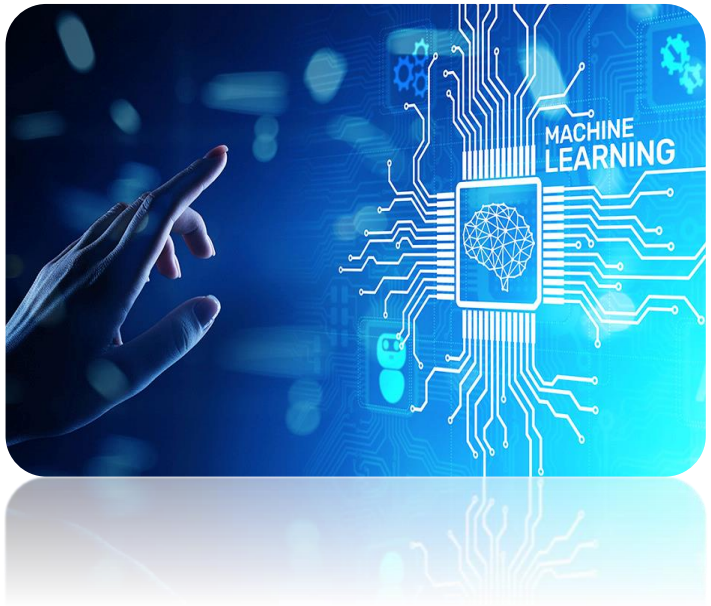
- Si l'ensemble de données contient des caractéristiques non pertinentes ou du bruit, les calculs de distance seront faussés



Sensibilité à la Dimensionnalité

- il devient difficile de trouver de "vrais" voisins proches, ce qui dégrade la performance

CONCLUSION



- **En raison de sa simplicité et de sa précision, le k-NN est l'un des premiers classificateurs appris par les débutants en science des données.**
- **Son principe repose sur la similarité entre les données : un nouvel élément est classé en fonction des catégories majoritaires de ses voisins les plus proches.**
- **Cet algorithme ne calcule aucun modèle prédictif et il rentre dans le cadre de l'apprentissage paresseux .**

QCM

Le KNN est un algorithme d'apprentissage:

- [ ] Semi-supervisé
- [ ] Supervisé
- [ ] Non supervisé
- [ ] Par renforcement

➡ supervisé

Quelle est la phrase qui résume le mieux le principe du KNN :

- [ ] Plus c'est complexe, mieux c'est
- [ ] L'algorithme apprend par essais et erreurs successifs
- [ ] La prédiction dépend uniquement de la donnée la plus proche
- [ ] Dis-moi qui sont tes voisins, je te dirai qui tu es

➡ Dis-moi qui sont tes voisins, je te dirai qui tu es

Avec KNN, un K trop petit risque de causer

- [ ] De l'underfitting
- [ ] De l'overfitting
- [ ] Un déséquilibre des classes
- [ ] Une normalisation des données

➡ l'overfitting

EXERCICES D'APPLICATION

QCM

Comment choisit-on la classe d'un nouvel élément avec KNN ?

- [ ] Par un vote majoritaire parmi les k voisins les plus proches.
- [ ] En calculant une fonction de prédiction.
- [ ] En utilisant toujours k=1.
- [ ] Par apprentissage profond.

➡ Par un vote majoritaire parmi les k voisins les plus proches.

KNN est souvent appelé "algorithme paresseux". Pourquoi ?

- [ ] Il donne toujours des résultats approximatifs
- [ ] Il ne construit pas de modèle pendant l'apprentissage.
- [ ] Il utilise très peu de mémoire.
- [ ] Il est très lent à l'entraînement.

➡ Il ne construit pas de modèle pendant l'apprentissage.

Dans un dataset avec 1000 points, quel impact aura un K trop grand ?

- [ ] Le modèle deviendra trop spécifique.
- [ ] La décision se base sur trop de voisins éloignés.
- [ ] Le temps de calcul devient négligeable.

➡ La décision se base sur trop de voisins éloignés.

EXERCICES D'APPLICATION

Exercice I

Enoncé:

On dispose d'un jeu de données concernant des étudiants. Pour chaque étudiant, on connaît :

- Le nombre d'heures passées à étudier.
- La note obtenue à un test pratique (en pourcentage).
- Le résultat final à l'examen (**Réussite** ou **Échec**).

À l'aide de l'algorithme KNN, prédisez le résultat ("Réussite" ou "Échec") d'un nouvel étudiant ayant les données suivantes :

- Temps d'étude : 2 heures
- Score au test : 75%

NB: Supposons que K=3.

Temps de révision (en heures)	Résultat du test (%)	Résultat
2	85	Réussi
3	70	Échoué
5	90	Réussi
1	60	Échoué
4	80	Réussi

EXERCICES D'APPLICATION

Exercice 1

Correction:

1. Identifier les variables

- La caractéristique X_1 (Heures d'étude) = 2
- La caractéristique X_2 (Note au test) = 75

Le point représentant le nouvel étudiant a donc pour coordonnées : (2, 75).

2. On calcule la distance euclidienne entre le point (2, 75) et tous les autres points du jeu d'entraînement.

$$\text{Distance} = \sqrt{[(X_2 - X_1)^2 + (Y_2 - Y_1)^2]}$$

- la distance entre(2, 75) & (2, 85) est égale à 10
- la distance entre(2, 75) & (3, 70) est égale à 5.1
- la distance entre(2, 75) & (1, 60) est égale à 15.1
- la distance entre(2, 75) & (4, 80) est égale à 5.4
- la distance entre(2, 75) & (5, 90) est égale à 15.8

➡ Puisque notre k=3 alors les 3 plus proches voisins du point étudié sont:

(3, 70),(4, 80),(2, 85)

⬇

Sur les **3 plus proches voisins** :

- 2 ont **réussi** l'examen
- 1 a **échoué**

Conclusion : Le modèle prédit une **RÉUSSITE** pour le nouvel étudiant.

EXERCICES D'APPLICATION

Exercice 2

Enoncé:

Supposons qu'une compagnie d'assurance (CNAM) veut savoir si une personne va souscrire à une assurance santé ou non.

On dispose d'un petit jeu de données de **clients qui ont acheté ou non une assurance santé.**

Pour chaque client on connait :

- son Âge (en années)
- de son salaire mensuel (en dinars)
- Achat assurance : **Oui = 1**, **Non = 0**

➡ Prédisez, en utilisant l'algorithme KNN, si une nouvelle personne X achètera une assurance santé ou non sachant qu'elle a :

- **l 'âge de 40 ans**
- **un salaire de 3200 dinars**

NB: Supposons que K=3.

Âge(en années)	Salaire (dinars)	Achat assurance
25	2000	1
30	2500	1
35	1800	0
50	4000	1
45	3000	0
60	3500	1

EXERCICES D'APPLICATION

Exercice 2

Correction:

Âge(en années)	Salaire (dinars)	Achat assurance	**Distance avec X (40, 3200 dt)**
25	2000	1	**1200.09**
30	2500	1	**700.07**
35	1800	0	**1400.01**
50	4000	1	**800.06**
45	3000	0	**200.06**
60	3500	1	**300.67**

On calcule la distance euclidienne entre le point (40,3200) et tous les autres points du jeu d'entraînement.

Distance = $\sqrt{[(X_2 - X_1)^2 + (Y_2 - Y_1)^2]}$

Exemple: $\sqrt{[(3200 - 2000)^2 + (40 - 25)^2]} = 1200.09$

➡ Les plus proches voisins (k=3 dans ce cas) sont les personnes éloignées de la nouvelle par les distances: (200.06), (300.67) et (700.07).

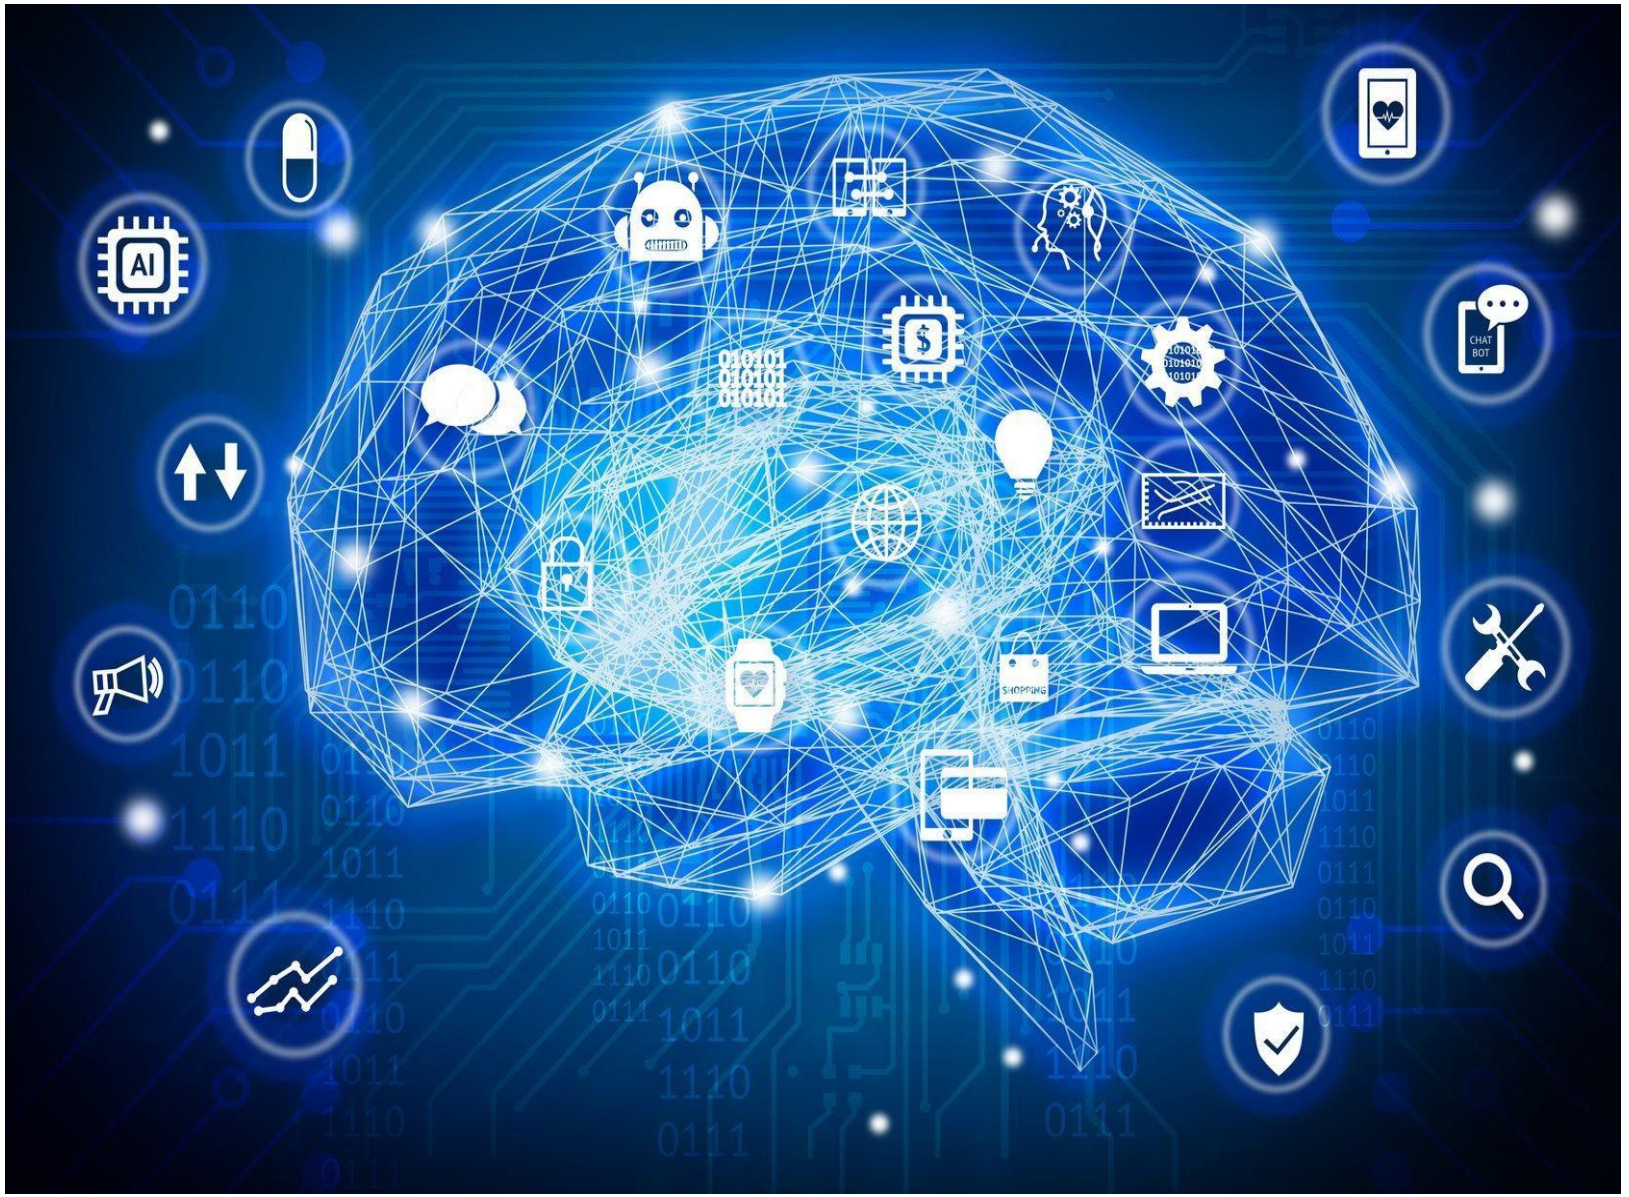
⇩

Leurs décisions d'achat : 0, 1, 1

Majorité → 1 (Oui)

Conclusion : Cette personne achètera une assurance santé selon le modèle k-NN (k=3).

EXERCICES D'APPLICATION



MERCI DE VOTRE ATTENTION