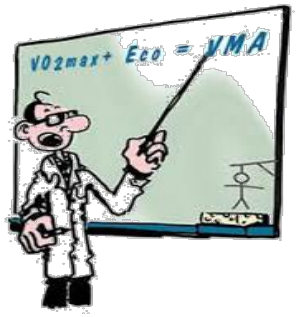


Traitement de Big Data Avancé

Elaboré par Dr. Souheyl MALLAT

Souheyl.mallat@gmail.com

2025-2026



NB: Ce document doit être complété par les notes du cours

Pourquoi ce cours ?

- Selon LinkedIn, les compétences les plus recherchées depuis plusieurs années sont :

    1) **Cloud and Distributed Computing** (Hadoop, Big Data)
    2) **Statistical Analysis and Data Mining** (R, Data Analysis)

- 10) **Storage Systems and Management** (SQL)

Objectifs généraux

- Ce cours présente des outils et méthodes de traitement de gros volumes de données (Big Data) au travers de la suite logicielle Hadoop.

- Hadoop est un ensemble de services et d'applications permettant de stocker et d'administrer des fichiers et des bases de données de très grande taille et de lancer des programmes de calcul sur ces données.

- Le principe est de répartir les données et les traitements sur un groupe de plusieurs machines appelé amas (cluster).

- Hadoop est utilisé par des entreprises comme Google, Facebook, Amazon, etc

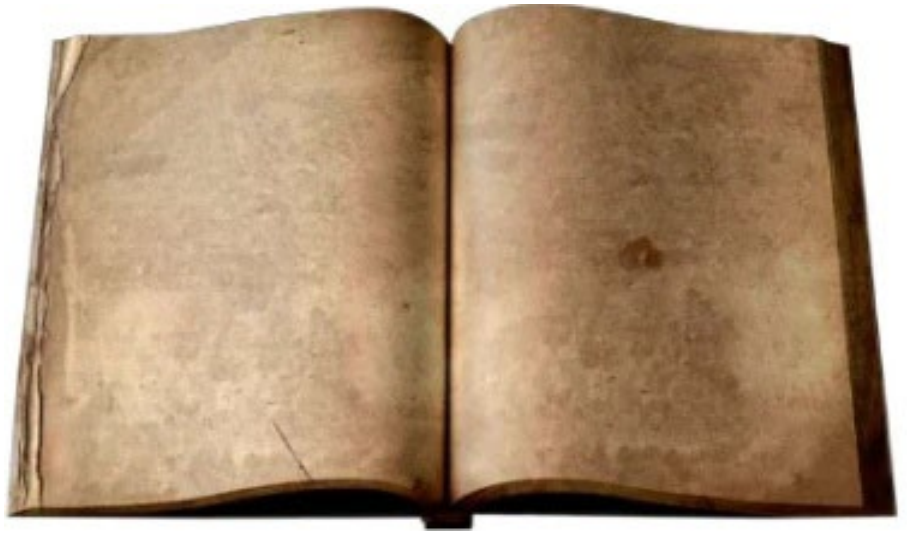
- Prérequis :
  - Langage Java
  - Langage Python de base
  - Bases de données
  - Systèmes d'exploitation

Chapitre 1: Introduction au Big Data



Un peu d’Histoire

Il a inventé le livre pour tout noter



Un peu d’Histoire

Et le téléphone pour tout dire



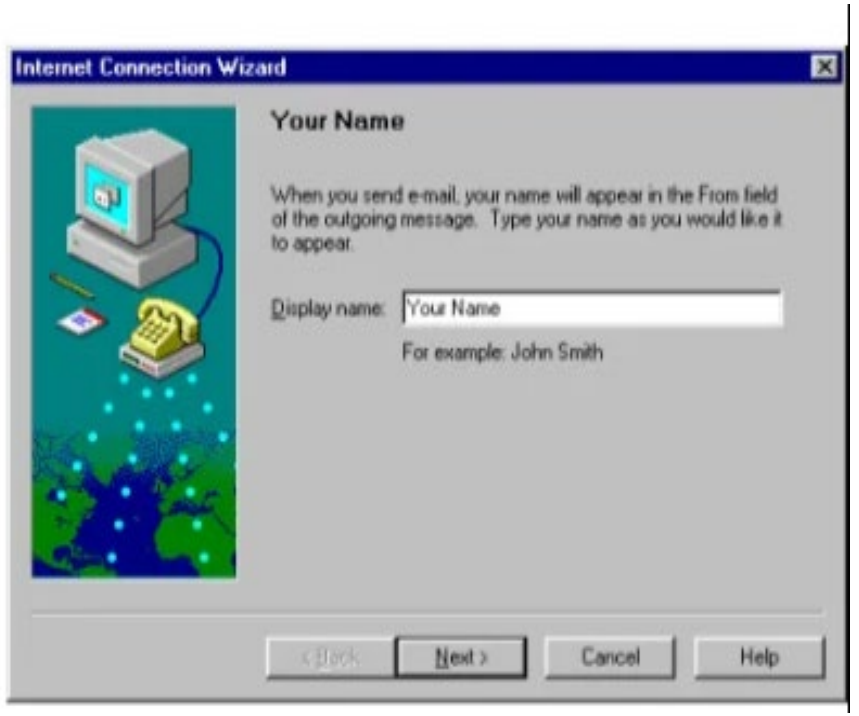
Un peu d’Histoire



Il voulait une machine qui ferait le travail à sa place…

Un peu d’Histoire

Puis partager ses trouvailles avec d’autres



Un peu d’Histoire



A début, une poignée de privilégiés avaient le **monopole** de l’information sur Internet

Un peu d’Histoire



Un peu d'Histoire

Et puis un jour…

Il était une fois …
World Wide WEB



Un peu d'Histoire



Un peu d'Histoire



Un peu d'Histoire



Un peu d’Histoire

Et avec l’arrivée des Plateformes Mobiles Intelligentes



Un peu d'Histoire

Web 3.0: Web Sémantique (?)



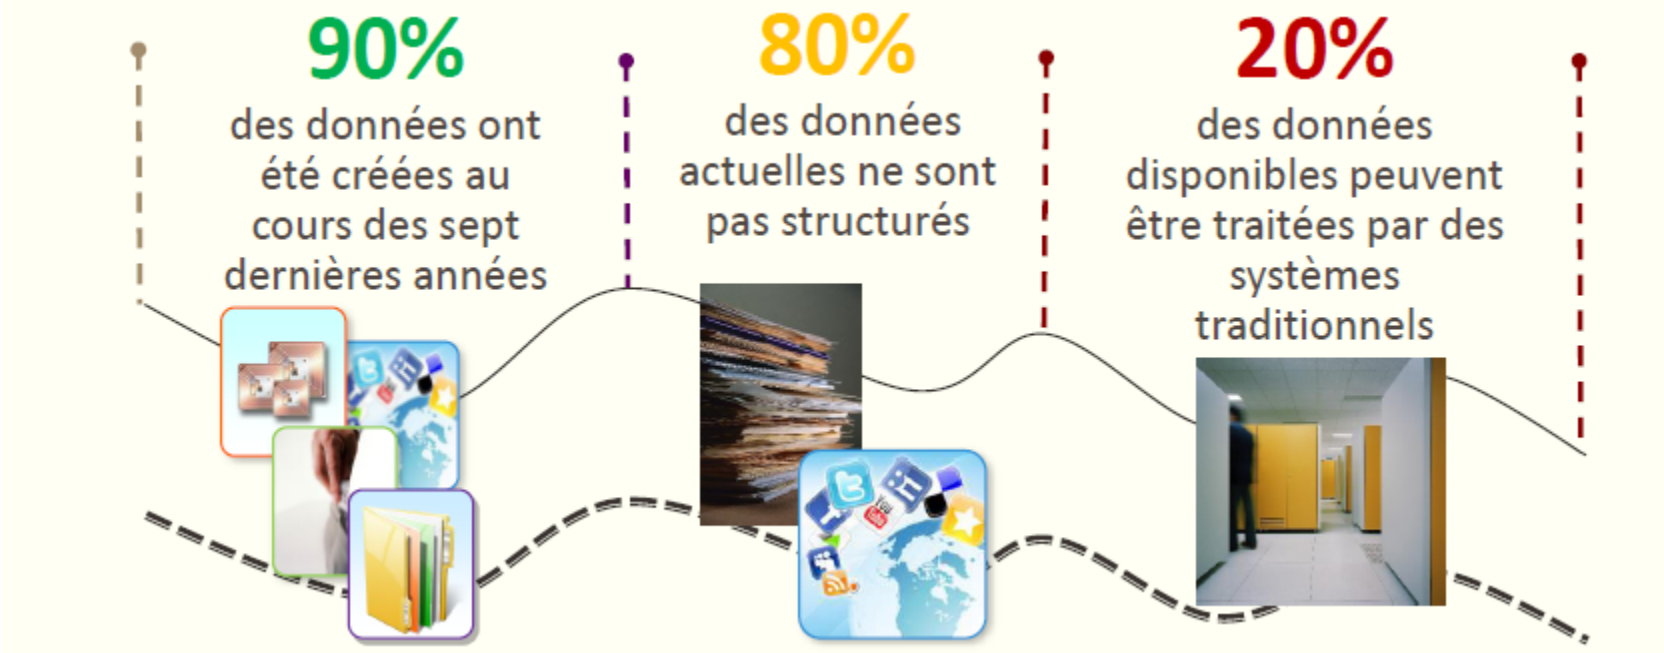
Un peu d’Histoire



Un peu d’Histoire



L’évolution de données



Challenges



? Réunir un grand volume de données variées pour trouver de nouvelles idées.

? Difficulté pour sauvegarder toutes ces données.

? Difficulté pour traiter ces données et les utiliser.

? Les données sont créées rapidement.



Les données ont explosé!


BIG DATA

Big Data : Intérêts

- **1/3**
  - Chefs d'entreprise prennent fréquemment des décisions basées sur des informations en lesquelles ils n'ont pas confiance, ou qu'ils n'ont pas.
- **1/2**
  - Chefs d'entreprise disent qu'ils n'ont pas accès aux informations dont ils ont besoin pour faire leur travail.
- **83%**
  - Des DSI (Directeurs des SI) citent : l'informatique décisionnelle et analytique comme faisant partie de leurs plans pour améliorer leur compétitivité.
- **60%**
  - Des PDG ont besoin d'améliorer la capture et la compréhension des informations pour prendre des décisions plus rapidement.

Big Data : Sources

- **Sources multiples** : sites, Bases de Données, téléphones, serveurs :
  - Détecter les sentiments et les réactions des clients.
  - Détecter les conditions critiques ou potentiellement mortelles dans les hôpitaux, et à temps pour intervenir.
  - Prendre des décisions risquées basées sur des données transactionnelles en temps réel.
  - Identifier les criminels et les menaces à partir de vidéos, sons et flux de données.
  - Étudier les réactions des étudiants pendant un cours, prédire ceux qui vont réussir, d'après les statistiques et modèles réunis au long des années (domaine Big Data in Education).

- Les données massives sont le résultat de la rencontre de trois éléments essentiels qui sont :

- L'Internet permet la transmission de l'information quelle que soit sa forme sur les appareils intelligents :

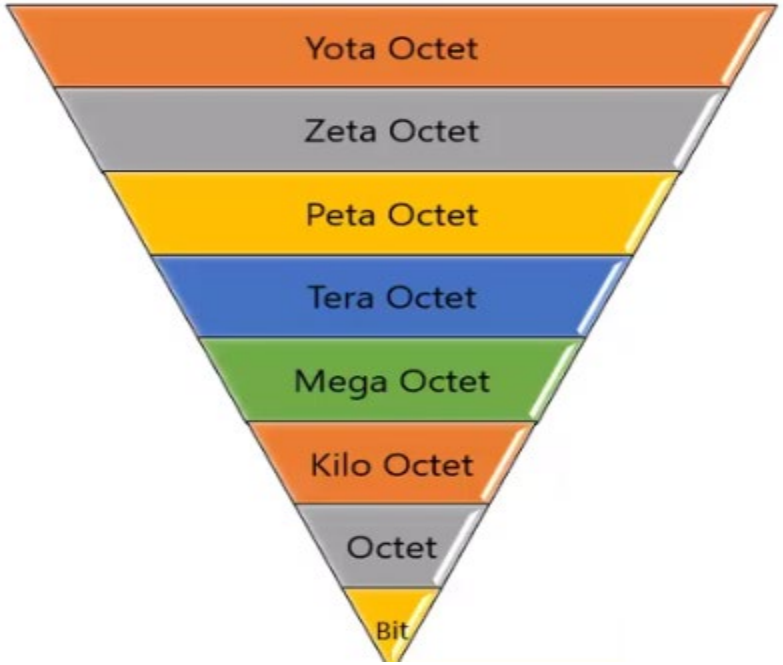
Les origines du Big Data ?

Préfixes multiplicatifs

- Avant de parler de BigData, connaissez-vous les préfixes ?

Ordre de mesure de stockage des données

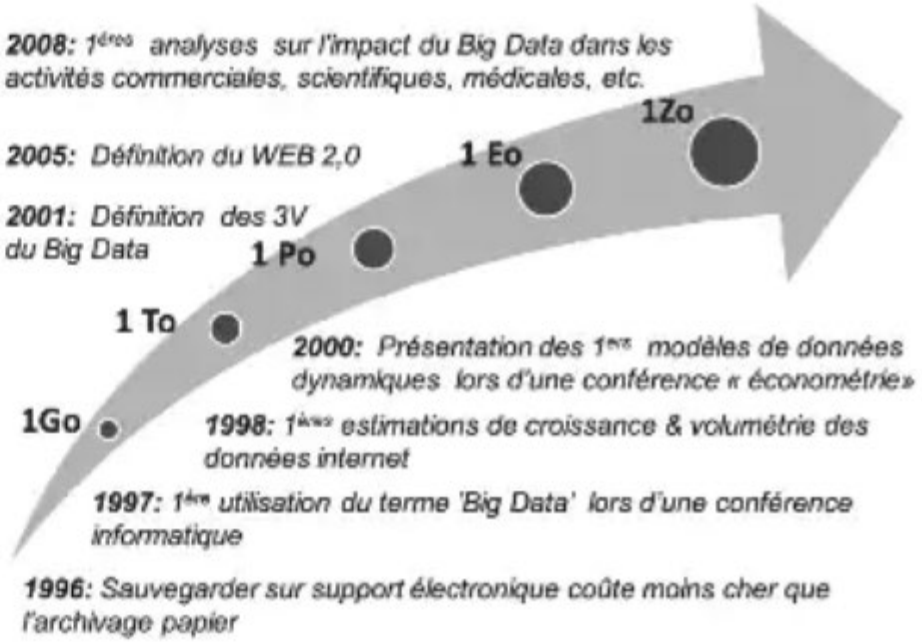
- 1 caractère => 1 octet
- 1 Page de texte =>30 ko (1ko=1024 o)
- 1 Morceau de musique => 5Mo (1Mo=1024 ko)
- 1 Film de 2H => 1Go (1Go=1024 Mo)
- 6 Millions de Livres => 1 To (1To=1024 Go)
- 2 Millard de Photos Rés Moyenne => 1 Po (1 Po=1024 To)
- Toutes les infos produites jusqu'à 2003 => 5 ExaO (1Eo=1024 Po)
- Données produites en 2011 => 1,8 ZetaO (1Zo=1024 Eo)
- En 2013 le plus grand data center au monde est capable de traiter 1 YotaO (1Yo=1024 Eo)



Les origines du Big Data ?

Historique et contexte

- L'évolution du SI amène les entreprises à traiter de plus en plus de données issues de sources toujours plus variées.
- Les prévisions de taux de croissance des volumes de données traitées dépassent les limites des technologies traditionnelles.
- On parle de Petaoctet (billiard d'octets) (ou Petabyte) voir de Zettaoctet (Trilliard d'octets) (ou Zettabyte).
  ⇒ Quelle solution pour exploiter ces données ?



Les origines du Big Data ?

- Les deux principales causes de l'avènement du Big Data ces dernières années sont à la fois **économiques** et **technologiques**!

Une baisse exponentielle des prix des ressources IT!

Qu'il s'agisse de la capacité de stockage, du nombreux de nœuds que l'on peut mettre en parallèle dans un data center, de la fréquence des CPU ou encore de la bande passante disponible (qui a favorisé l'émergence des services cloud), etc

Les origines du Big Data ?

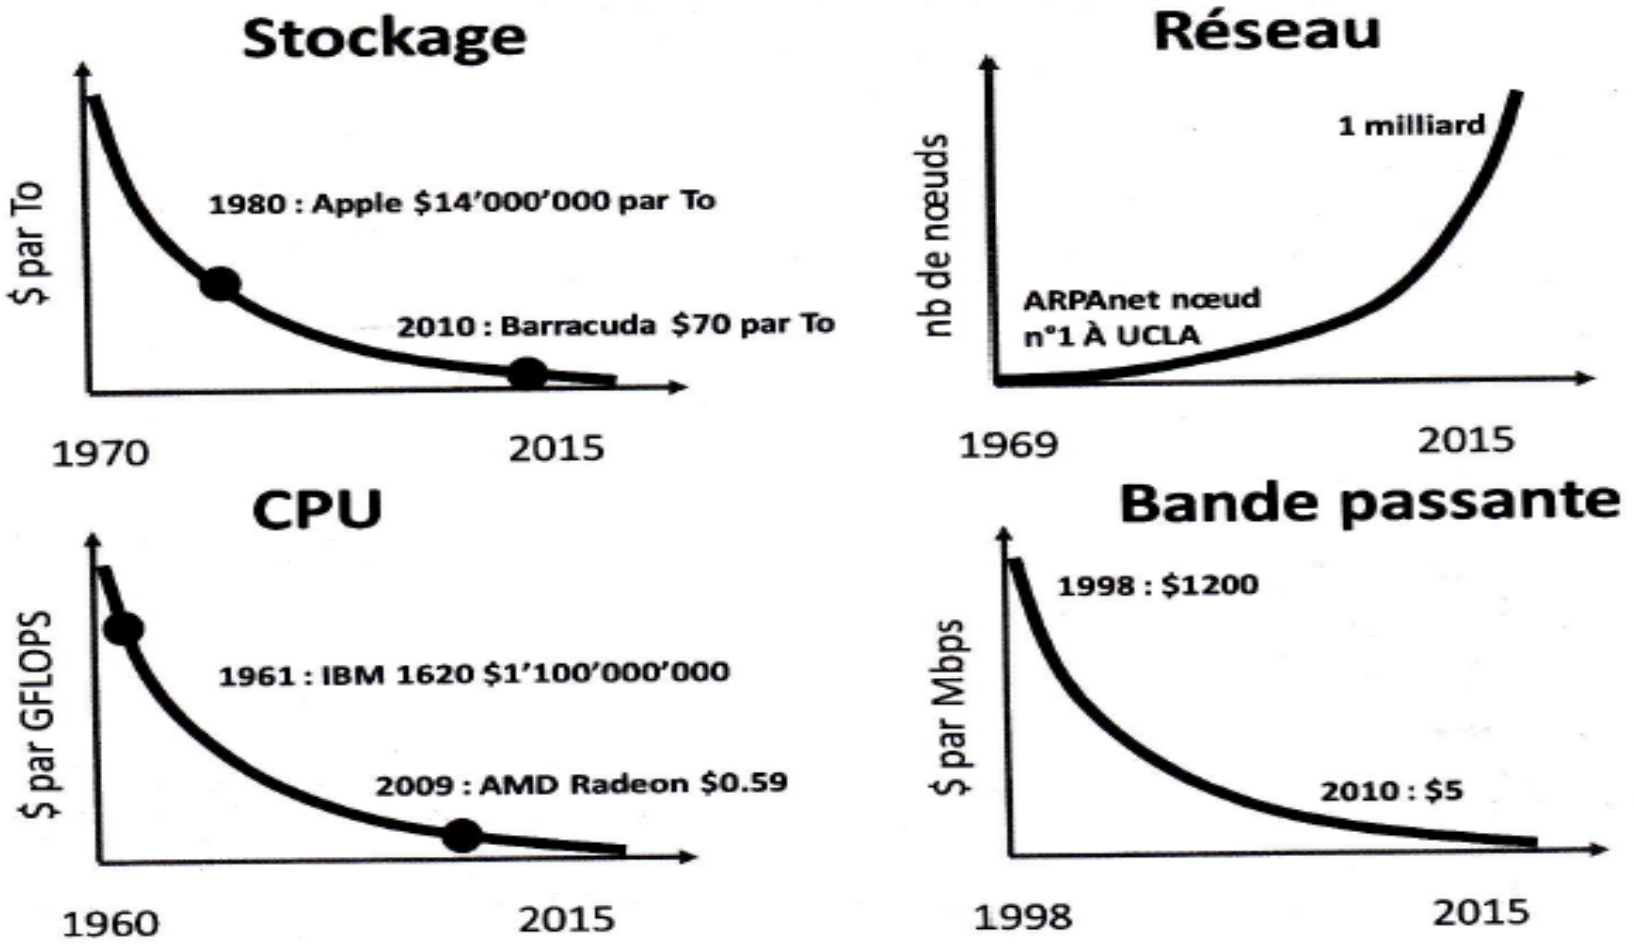


Figure: Evolution des prix des ressources IT au cours des dernières décennies

Les origines du Big Data ?

Data center

Imaginez 5000 ordinateurs connectés entre eux formant un cluster :



Les origines du Big Data ?

Des progrès initiés par les géants du web

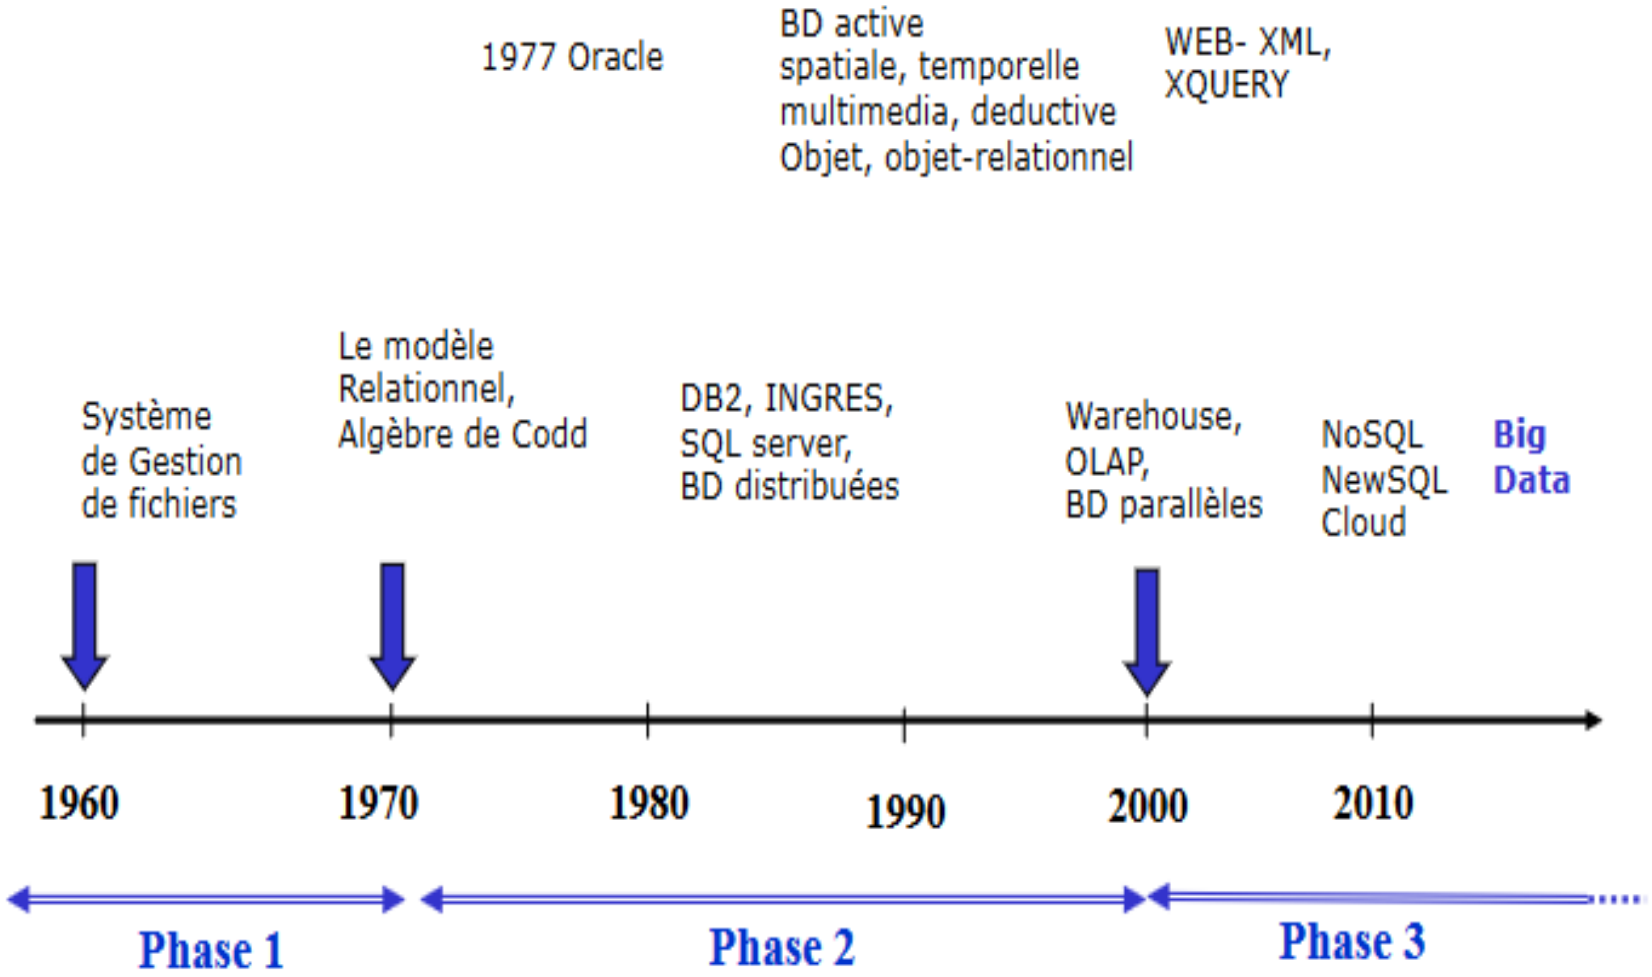
- Pour bénéficier de ces ressources de stockage énorme, les géants du web ont du développer pour leurs propres besoins de nouvelles technologies notamment en matière de parallélisation des traitements opérant des volumes de données se chiffrant en plusieurs centaines de téraoctets

Les origines du Big Data ?

Question: Où se trouve la frontière du Big Data ?

- Des volumes qui relèvent du Big Data à partir du moment où ces données ne peuvent plus être traitées en un temps "raisonnables " ou "utiles« par des systèmes constitués d'un seul nœud.
  - Exemple: Si l'on doit traiter ou analyser un téraoctet de données„ en quelques minutes il faudra impérativement recouvrir à une mise en parallèle des traitements et du stockage sur plusieurs nœuds!

Les origines du Big Data ?



C’est quoi le Big Data ?

- **Définition1** : « data of a very large size, typically to the extent that its manipulation and management present significant logistical challenges » Oxford English Dictionary, «données de très grande taille, dont la manipulation et gestion présentent des enjeux du point de vue logistiques »
- **Définition2** : « an all-encompassing term for any collection of data sets so large and complex that it becomes difficult to process using on-hand data management tools or traditional data processing applications » Wikipédia, « englobe tout terme pour décrire toute collection de données tellement volumineuse et complexe qu’il devient difficile de la traiter en utilisant des outils classiques de traitement d’applications »
- **Définition 3**: « datasets whose size is beyond the ability of typical database software tools to capture, store, manage, and analyze » McKinsey, 2011, « collections de données dont la taille dépasse la capacité de capture, stockage, gestion et analyse des systèmes de gestion de bases de données classiques»

C’est quoi le Big Data ?

Big Data :Un peu d’Histoire

Big Data

- Terme apparu en premier en 1997
- Décrit les défis technologiques à relever pour visualiser un grand ensemble de données
- A pris toute son ampleur avec l'avènement du Web 2.0



C’est quoi le Big Data ?

- Ce qu’on retient …
- Volume des données,
- Complexité,
- Limites des outils classiques de gestion des données,
- Passage à l’échelle

Big Data : Notions

Big Data = Big + Data

Données:
Deuxième bien le plus précieux au monde après l'Information

Différences:

- Valeur Ajoutée
- Exploitation
- Interprétation



C’est quoi le Big Data ?

- Explosion de la quantité de données,
- Le partage de données,
- La recherche des données,
- Stockage massif des données,
- Traitement des flux de données.

Big Data : Notions

Big Data = Big + Data

Big:

Question Fréquente

- Les systèmes traditionnels ne gèrent-ils pas des données volumineuses?

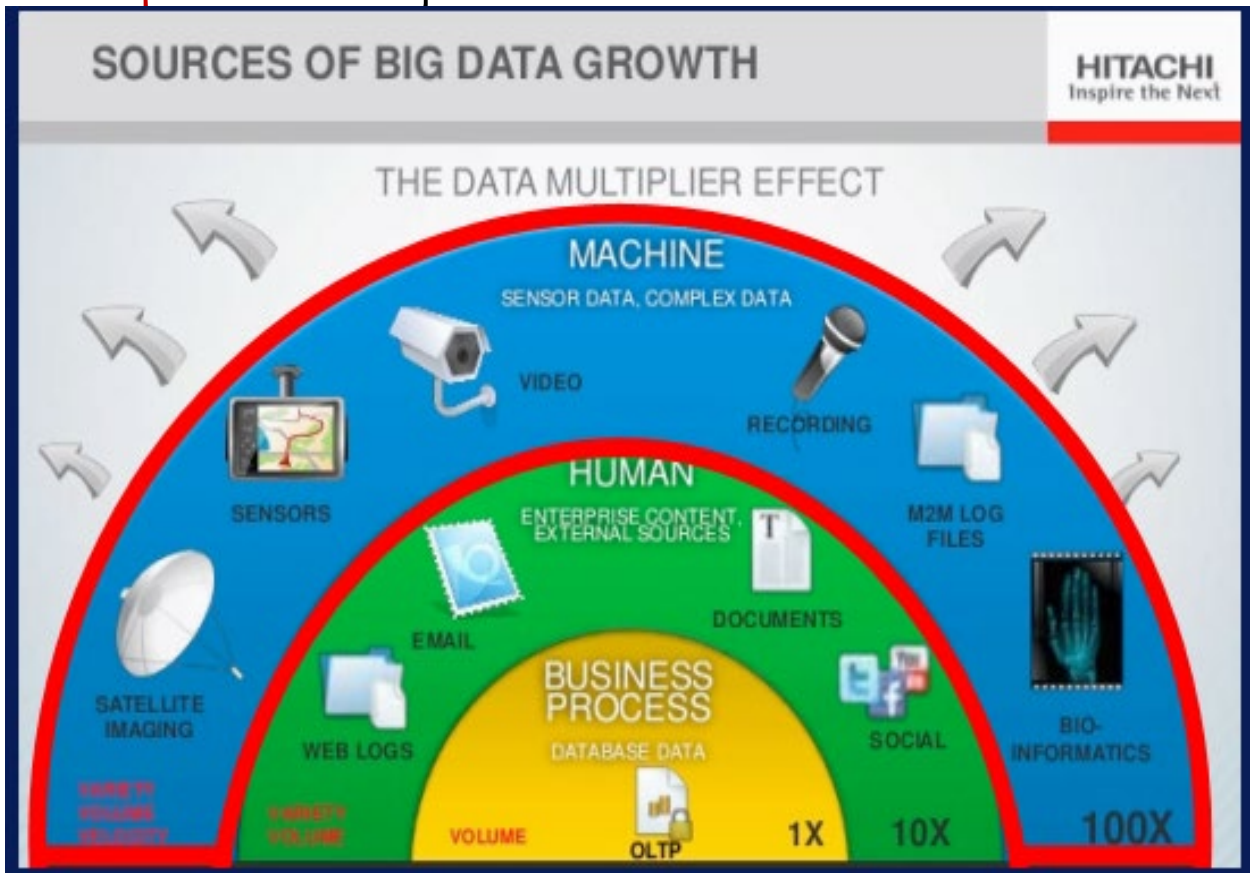
Données Massives ou Megadonnées

- Exaoctets (10^{18} o) voire Zettaoctets (10^{21} o)
- 90% des données récoltées depuis le début de l'humanité ont été générées les deux dernières années

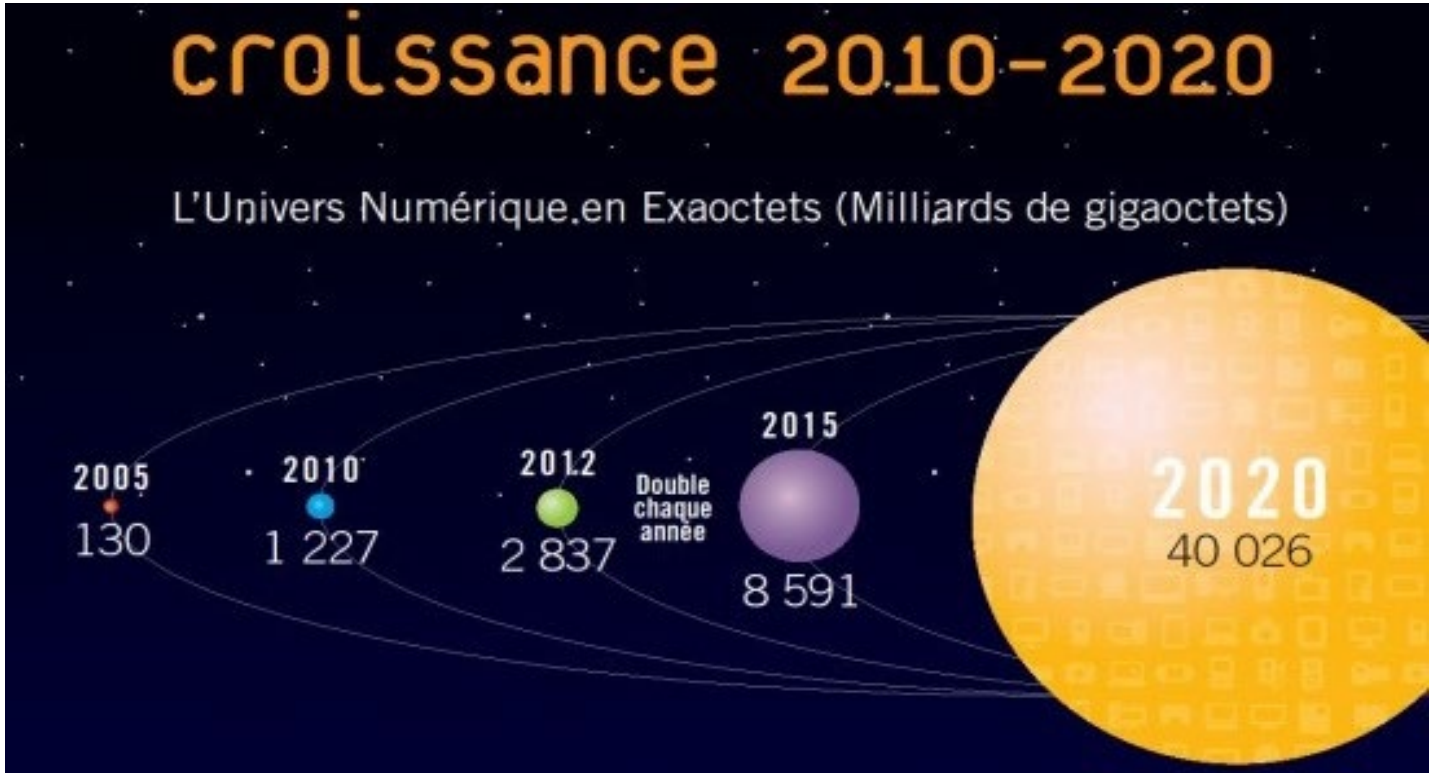
C’est quoi le Big Data ?

- Explosion de la quantité de données,

Les chercheurs font un énorme travail afin de découvrir une méthode pour traiter cette quantité massive qui arrivent chaque jour même en temps réel chaque seconde.



Explosion de la quantité de données!



- Il n'y avait que **130 exaoctets** de données dans l'univers numérique en 2005. Il devrait y en avoir plus de 40 000 en 2020.
- En 2012, **35%** de ces informations nécessiterait **une protection**, mais ce n'est le cas que pour 20% d'entre elles.
- En 2020, les données représenteront l'équivalent de plus de **5 000 GO par personne!**

Big Data : Notions

Big Data = Big + Data

Big: Volume énorme

Question Fréquente

- Les systèmes traditionnels ne gèrent-ils pas des données volumineuses?

IMPORTANT

⚠ L'objectif n'est pas de remplacer les systèmes existants avec les systèmes Big Data, mais de les intégrer ensemble!

C’est quoi le Big Data ?

- Explosion de la quantité de données,
- ➢ **Le partage de données**,
- La recherche des données,
- Stockage massif des données,
- Traitement des flux de données.

C’est quoi le Big Data ?

- Explosion de la quantité de données,
- **Le partage de données,**
  - Données partagées
  - Réplication des données
  - Restitution des données



C’est quoi le Big Data ?

- Explosion de la quantité de données,
- Le partage de données,
- ➢La recherche des données,
- Stockage massif des données,
- Traitement des flux de données.

C’est quoi le Big Data ?

- Explosion de la quantité de données,
- Le partage de données,
- La recherche des données,

Comment parcourir ces données et en extraire des informations facilement et rapidement?

- Données massives stockées quelques part,
- Rechercher une donnée précise,
- Il faut que la réponse soit optimisée:
  - → en terme de recherche
  - → en terme de résultat!



C’est quoi le Big Data ?

- Explosion de la quantité de données,
- Le partage de données,
- La recherche des données,
- Stockage massif des données,

Stockage massif des données



- Comment stocker les données dans un endroit fiable, qui soit moins cher!

- Les données sont massives et existent → Trouver les moyens de stocker ces données le plus pertinemment possible afin qu'on puisse les restituer et les traiter plus tard.

- Sauvegarder toutes ces données

C’est quoi le Big Data ?

- Explosion de la quantité de données,
- Le partage de données,
- La recherche des données,
- Stockage massif des données,
- Traitement des flux de données.

Traitement des flux de données

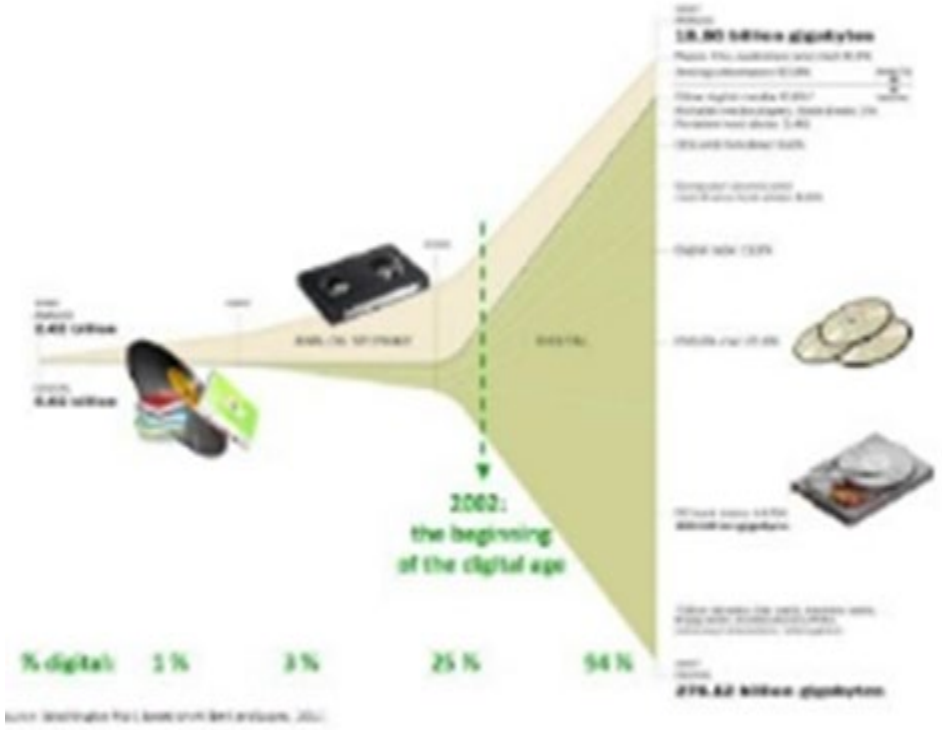


- Traitement des données énormes et dans un temps précis

- Egalement coût de traitement moins cher !

C’est quoi le Big Data ?

Big Data : Est-ce une innovation



- L'explosion des volumes des données nécessite une innovation en terme de :
  - **Acceleration matérielle** : Abandon des disques durs au profit des mémoires dynamiques DRAM (Dynamic Random Access Memory : mémoire vive dynamique) ou flash.
    ⇒ Meilleur benefice des processeurs multicœurs.

- **Bases de données d'analyse massivement parallèle** (MPP) : Ces bases de données conformes SQL sont conçues pour répartir le traitement des données sur plusieurs machines.
- Modèle **Map-Reduce, Hadoop** et autres approches **NoSQL** : Ces approches permettent d'accéder aux données via des langages de programmation sans utiliser les interfaces basées sur SQL et permettent de répartir les données sur plusieurs machines distinctes.

Quand peut-on dire qu'on a affaire à des BIG DATA?

Les n-V

C’est quoi le Big Data ?

On parle Aussi de:

- Mégadonnées,
- Données massives.

Question: ? Le Big Data=le volume de données

Réponse: Faux !

➡ Il n’y a pas que la volumétrie de données lorsqu’on parle de Big Data!!

BIG DATA: Caractéristiques

- Gartner (2001) – 3Vs



- IBM (2012) – 4Vs



- 2015 : encore plus de V

VALEUR

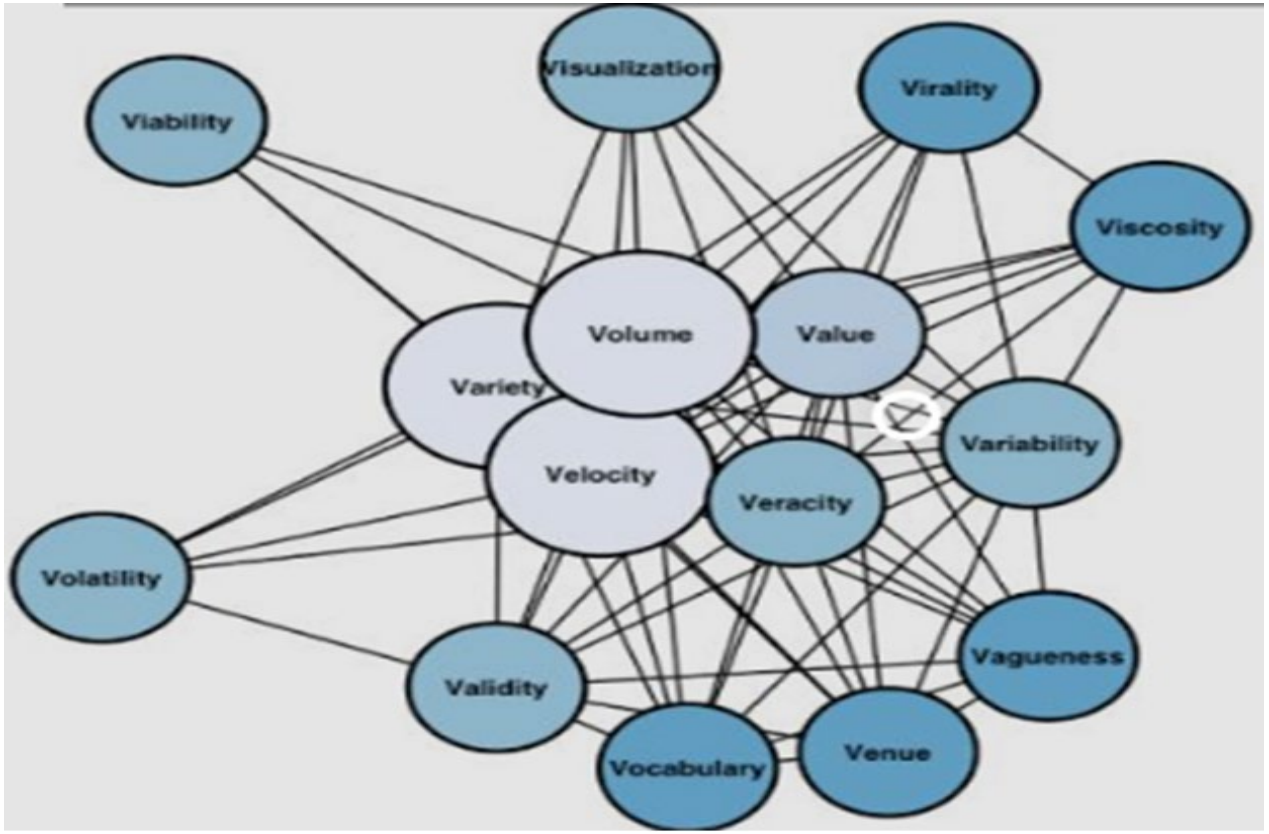
BIG DATA: Caractéristiques

- 2016 : 7V ?



BIG DATA: Caractéristiques

- 2017 : 10V ?



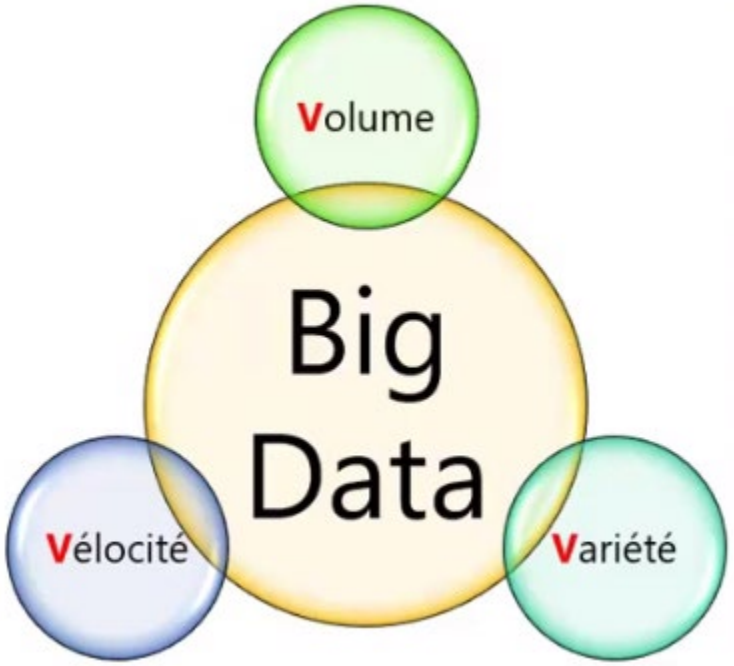
BIG DATA: Caractéristiques

3 Problématiques majeures pour les données massives

Volume →

Vélocité →

Variété→



BIG DATA: Caractéristiques

