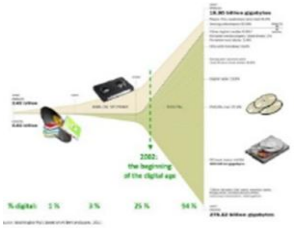
C'est quoi le Big Data ?

Big Data : Est-ce une innovation



- L'explosion des volumes des données nécessite une innovation en terme de :
  - **Acceleration matérielle** : Abandon des disques durs au profit des mémoires dynamiques DRAM (Dynamic Random Access Memory : mémoire vive dynamique) ou flash.
    ⇒ Meilleur benefice des processeurs multicœurs.

- **Bases de données d'analyse massivement parallèle** (MPP) : Ces bases de données conformes SQL sont conçues pour répartir le traitement des données sur plusieurs machines.
- Modèle **Map-Reduce, Hadoop** et autres approches **NoSQL** : Ces approches permettent d'accéder aux données via des langages de programmation sans utiliser les interfaces basées sur SQL et permettent de répartir les données sur plusieurs machines distinctes.

Quand peut-on dire qu'on a affaire à des BIG DATA?

Les n-V

BIG DATA: Caractéristiques

- Gartner (2001) – 3Vs



- IBM (2012) – 4Vs



- 2015 : encore plus de V



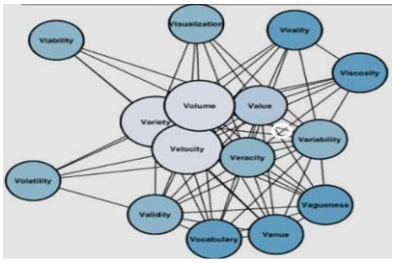
BIG DATA: Caractéristiques

- 2016 : 7V ?



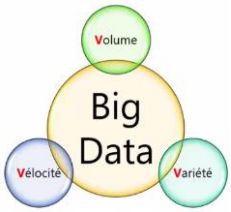
BIG DATA: Caractéristiques

- 2017 : 10V ?



BIG DATA: Caractéristiques

3 Problématiques majeures pour les données massives
Volume →
Vélocité →
Variété→



BIG DATA: Caractéristiques







– Outils numériques plus performants et plus connectés: ordinateurs et smartphones





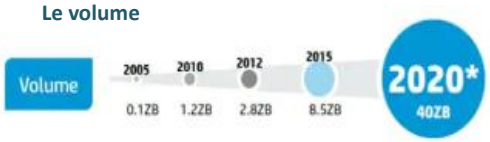
– Open Data
- Réseaux sociaux: facebook
- Données d'administrations publiques





– Internet des Objets
- RFID (cartes de transport, codes bar, …)
- Ericsson a estimé le nombre d'objets connectés dans le monde à 50 milliards en 2020 (12 milliards en 2013)

Le volume



- 4,4 zettaoctets de données
  = 4,4 trillion de gigaoctets
- En 2013, il y a autant de données que les étoiles connues dans tout l'univers.

- 44 zettaoctets de données
  = 44 milliards gigaoctets
- 62 fois le nombre de tous les sables dans toutes les plages de la terre.

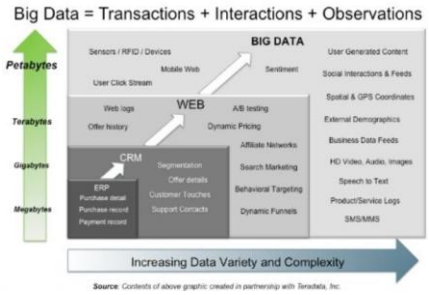
40 zettaoctets de données en 2020

50 milliards d'objets connectés à la même date

octets

1 Mégaoctet = 10^6 octets
1 Gigaoctet = 10^9 octets
1 Téraoctet = 10^{12} octets
1 Pétaoctet = 10^{15} octets
1 Exaoctet = 10^{18} octets
1 Zettaoctet = 10^{21} octets

Le volume

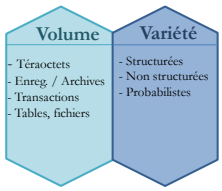




Les 5 V de Big Data

La variété (Variety)

- Pour un stockage dans des bases de données ou dans des entrepôts de données, les données doivent respecter un format prédéfini!



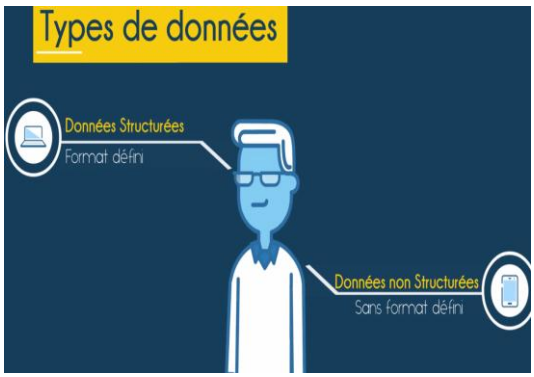
Mais!



- La plupart des données existantes sont non-structurées ou semi structurées,
- Les données sont sous plusieurs formats et types (fichiers xml, json, txt, base de données relationnelle, etc),

15

La variété (Variety)

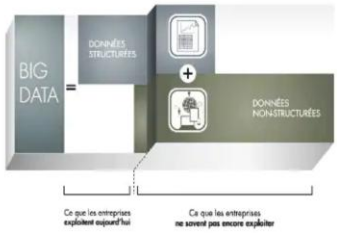


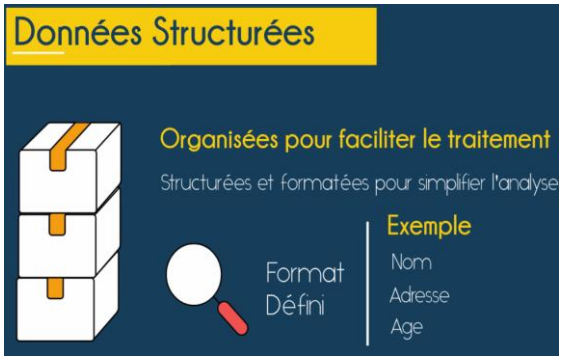
La variété (Variety)

Données structurées versus Données non structurées

- Données structurées : Données que l'on peut clairement codifier et identifier.
- Les données d'un tableur sont typiquement des données structurées.
- On peut comprendre leurs significations en croisant les titres de la ligne et colonne dans laquelle se trouent les données.
  ⇒ Les systèmes d'analyse algorithmique ont depuis toujours été développés pour traiter ce type de données.

- Données non structurées : Données qui ne répondent pas à un codage qui permet d'en tirer de l'information.
- C'est en analysant les contenus des messages que l'on déduit l'information : fichiers texte, audio, vidéo, etc. que l'on peut clairement codifier et identifier.





Données structurées: Exemple

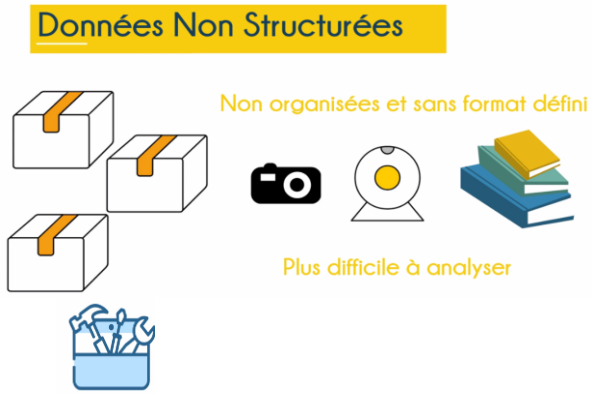
Results | Messages

	EmployeeId	FirstName	LastName	DepartmentName
1	1	Ken	Sanchez	Executive
2	2	Terri	Duffy	Engineering
3	3	Roberto	Tamburello	Engineering
4	4	Rob	Walters	Engineering
5	5	Gail	Erickson	Engineering
6	6	Jossef	Goldberg	Engineering
7	7	Dylan	Miller	Support
8	8	Diane	Margheim	Support
9	9	Gigi	Matthew	Support
10	10	Michael	Raheem	Support



Semi-structuré
Exemple: fichier XML

```
<rec><name>Prashant Rao</name><sex>Male</sex><age>35</age></rec>
<rec><name>Seema R.</name><sex>Female</sex><age>41</age></rec>
<rec><name>Satish Mane</name><sex>Male</sex><age>29</age></rec>
<rec><name>Subrato Roy</name><sex>Male</sex><age>26</age></rec>
<rec><name>Jeremiah J.</name><sex>Male</sex><age>35</age></rec>
```



Données non structurées: Exemple







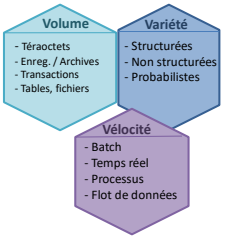
C'est quoi le Big Data ?

Les 5 V de Big Data

La vélocité /vitesse (Velocity)

« Au cœur du Time to Market »

- La fréquence d'arrivée des données,
- La vitesse de traitement des données,
- Les données doivent être stockées à l'arrivée, parfois même des ***Teraoctets*** par jour!
  - Sinon, risque de les perdre!



- Les entreprises se trouvent de plus en plus au milieu d'un flux continuel de données

26



Les 5 V de Big Data

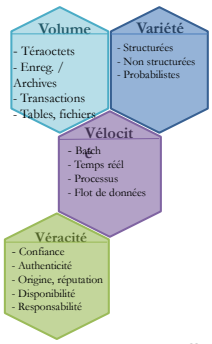
La véracité (Veracity)

- Fait référence à la fiabilité des données.
- Si la quantité des données augmente alors la qualité et précision sont moins vérifiées !

Exemple: Twitter →Les twittes peuvent contenir:

- Des abréviations, Les hashtags #, Langage familier, L'alphabet de tchat arabe, fiabilité et exactitude de données, etc.

- Les solutions Big Data et l'analytique doivent remédier à cela en se référant au volume des données existantes,
  - La manque de qualité et d'exactitude résultent souvent des gros volumes!

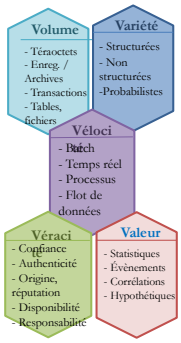


28

La valeur (Value)

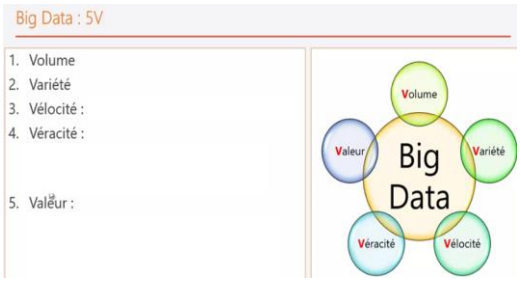
- Il faut transformer toutes les données en valeurs **exploitables:** les données sans valeur sont **inutiles,**
- Atteindre des objectifs stratégiques de création de valeur pour les clients et pour l'entreprise dans tous les domaines d'activité.
- Il est aussi primordial que les entreprises évaluent la rentabilité d'une récolte de données par exemple.

→Un projet Big Data et son accès aux utilisateurs n'a d'intérêt que s'il apporte de la valeur à l'entreprise → Le V le plus important!



29

Résumé



Problématique du Volume

▪ Auparavant, quand les systèmes d'application de gestion de base de données ont été réalisés, ils ont été construits avec **une échelle à l'esprit**. Même les organisations **n'ont pas été préparées à l'échelle** que nous produisons aujourd'hui.

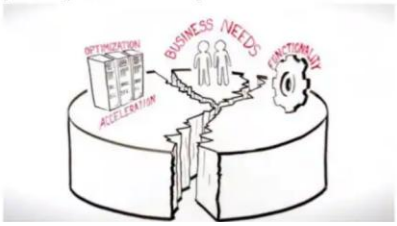
▪ Comme les exigences de ces organisations ont augmenté au fil du temps, ils doivent repenser et réinvestir dans l'infrastructure. Actuellement, le coût des ressources impliquées dans l'extension de l'infrastructure, s'augmente avec un facteur exponentiel.

▪ De plus, il y aurait une **limitation** sur les différents facteurs tels que la **taille** de la machine, **CPU, RAM,** etc. qui peuvent être mis à l'échelle (scaled up). Ces systèmes **traditionnels** ne seraient pas en mesure de soutenir l'échelle requise par la plupart des entreprises.

Problématique du Volume

ADAPTABILITE

▪ Dans ce nouveau contexte, les **méthodes de traitement de ces données** (capture, stockage, recherche, partage, analyse, visualisation) **doivent être redéfinies** car **l'ensemble de ces données deviennent difficilement manipulables par les outils classiques**.



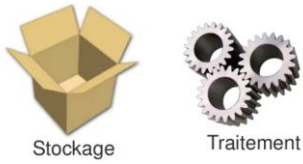
Arrêter de réfléchir en
Relationnel!



Absolument TOUTES les
Données sont
Importantes!

Mais tout de même…
Comment Gérer ces

2 Grands Challenges



Comment le Big Data gère ces situations complexes?