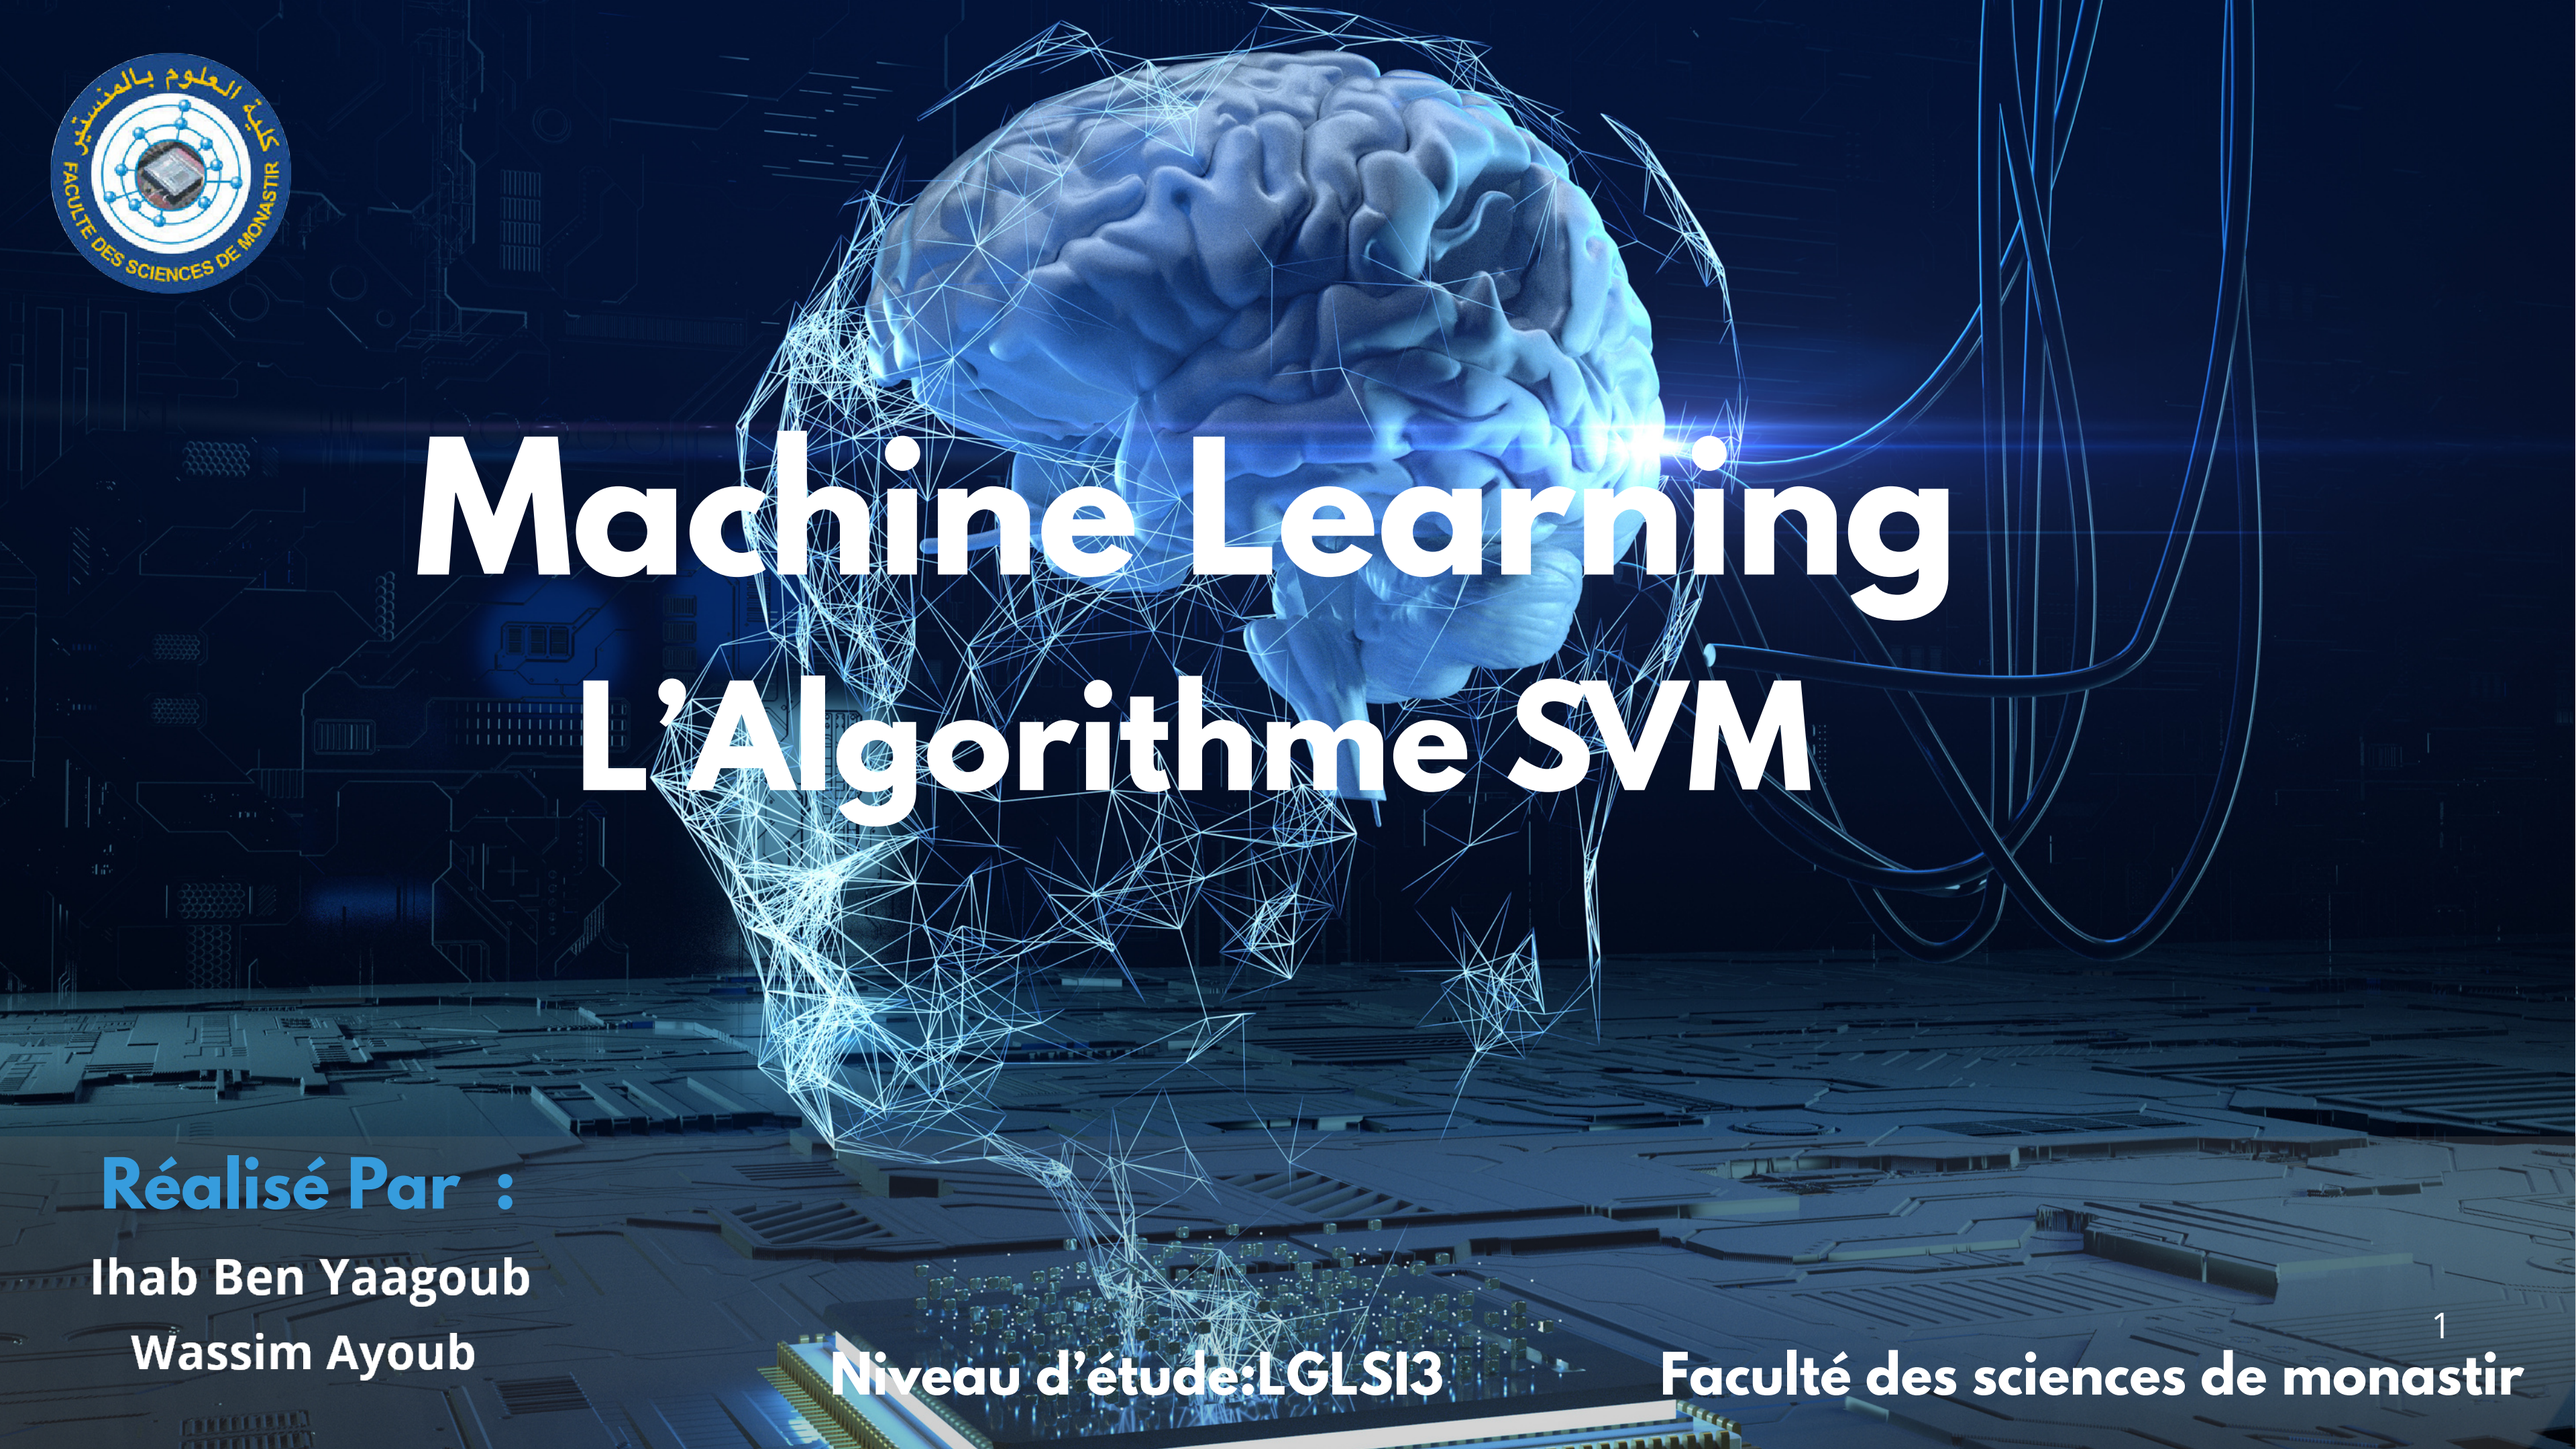

Machine Learning
L'Algorithme SVM

Réalisé Par :

Ihab Ben Yaagoub

Wassim Ayoub

Niveau d'étude:LGLSI3

Faculté des sciences de monastir

Plan

Introduction 1

Le Problème d'Apprentissage 2

Principes de Base des SVM 4

Cas Linéaire Séparable 5

Cas Linéaire non Séparable 8

Cas Non Linéaire Séparable 10

Étapes du fonctionnement du SVM 13

Conclusion et Perspectives 15

C’est Quoi le SVM ?

- **SVM (Support Vector Machines) est un *algorithmes d’apprentissage supervisé* Utilisés surtout pour *la classification* développer en 1990 Par Vladimir Vapnik**
- **Ils cherchent à trouver la frontiére optimal qui sépare le mieux les classes en maximisant la distance entre elles.**
- **La distance entre les classes est appellé : *Marge***

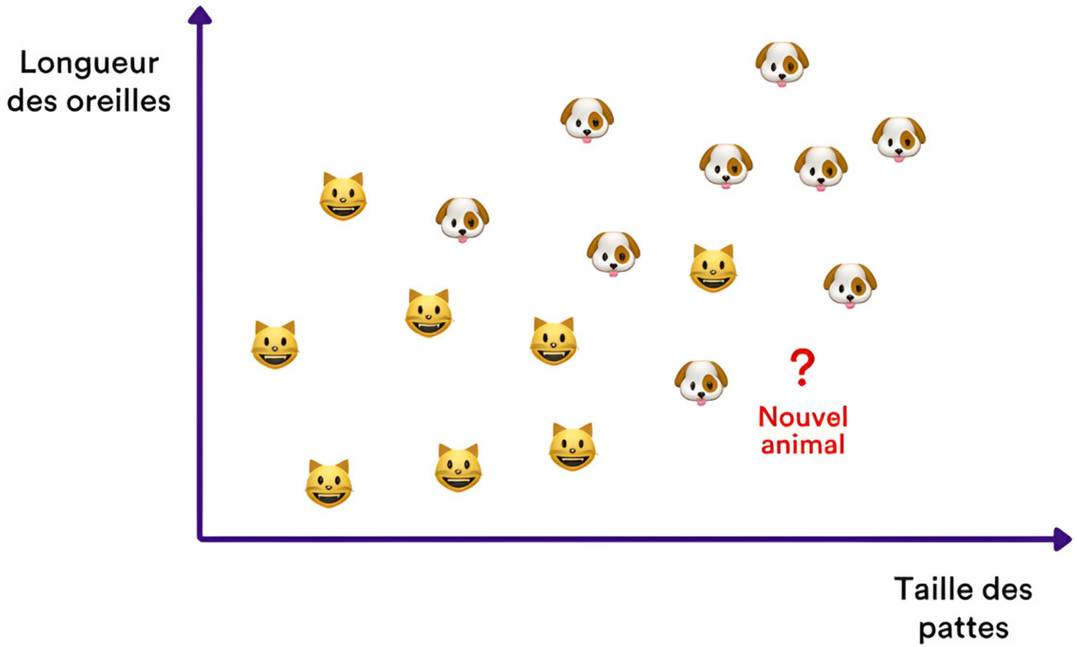

Problémes D’apprentissage

- **Apprentissage supervisé = Prédire une sortie à partir d’entrées avec des exemples**
- **Prédire une sortie y (ex: spam ou non) à partir de x (ex : mots dans un email).**
- **Utilise un ensemble d’exemples S={(x1,y1),…, (xn,yn)}**

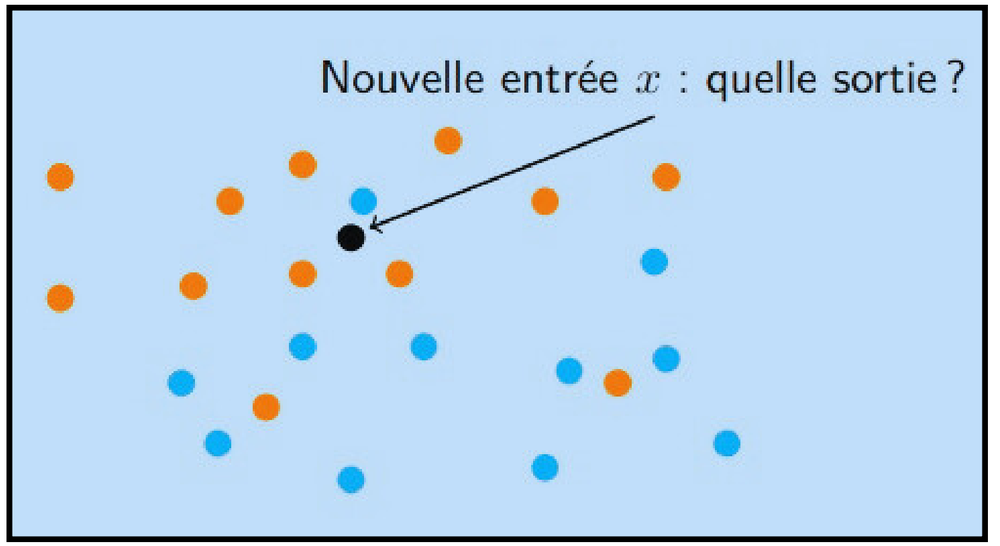

Exemple de problèmes :

- **Reconnaissance de formes =>chiffres manuscrits, visages**
- **catégorisation de textes=> spam**
- **diagnostic médical (cancer) – illustrer avec des cas concrets des documents**

Défis de l’algorithme

Minimiser les erreurs sur de nouvelles données

Modéle plus précis

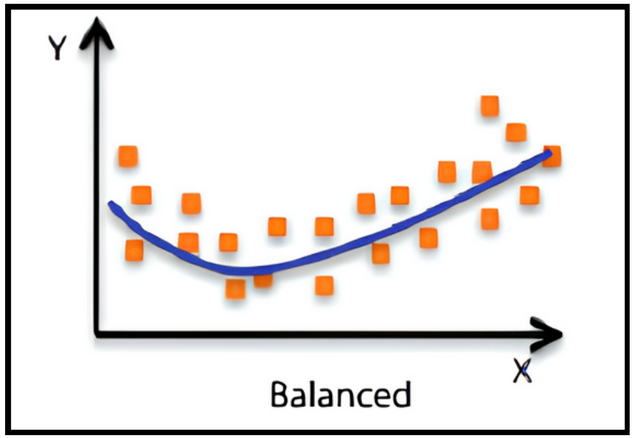

Sous-apprentissage

Ignore les détails, fait des erreurs.

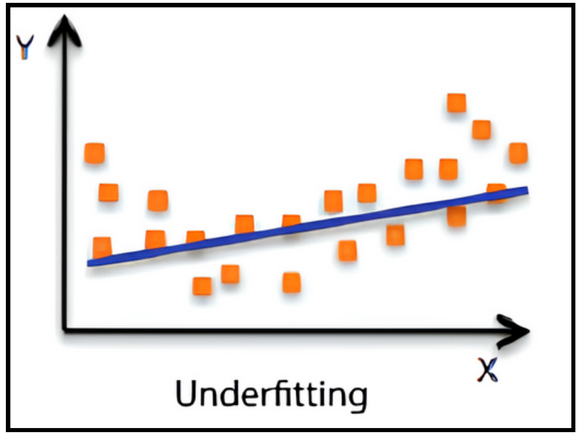

Sur-apprentissage

Collé aux données, échoue ailleurs

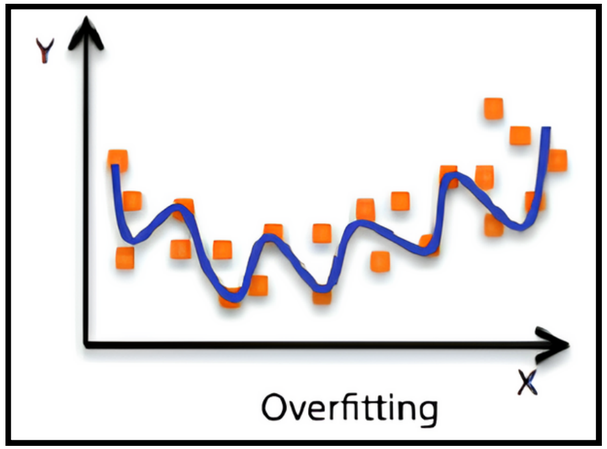

Principes de Base des SVM

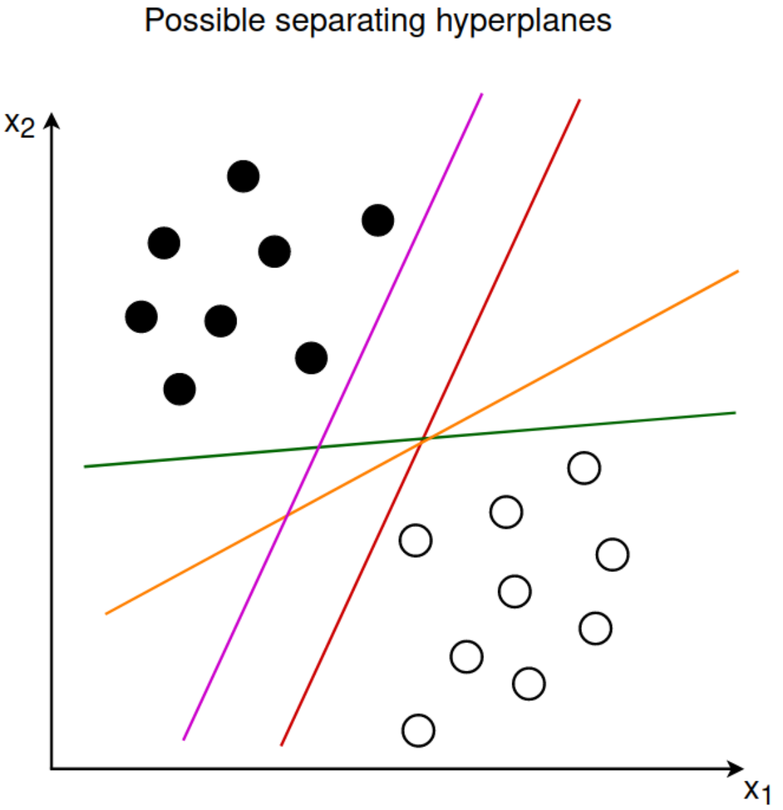

- Chaque prédiction d'un SVM repose sur une fonction de décision f(x) et la valeur $y \cdot f(x)$ permet de mesurer la confiance du modèle dans sa classification. D'où :
- Si la contrainte y.f(x) >= 1 alors *"Bonne classification "*
- Sinon : *"Mauvaise classification "*
- les SVM cherchent à déterminer l'hyperplan optimal.

Remarque :

la résolution avec SVM se divise en plusieurs cas :

Cas linéaire séparable

Quand les données peuvent être séparées parfaitement, le SVM cherche l'hyperplan optimal, celui qui maximise la distance (la marge) entre les points des deux classes.

Equation de hyperplan :

f(x)=0 => y = m.x+b $m = \frac{y_2 - y_1}{x_2 - x_1}$

la fonction de décision est définie par :

f(x)=w.x+b => f(x)=m.x+b-y

w : représente le vecteur normal à l'hyperplan (de cordonne [m,-1])

X : est le vecteur[x,y]

b : le biais

Cette marge est calculée par :

$$\text{Marge} = \frac{2}{||w||}$$

$$||w|| = \sqrt{w_1^2 + w_2^2}$$

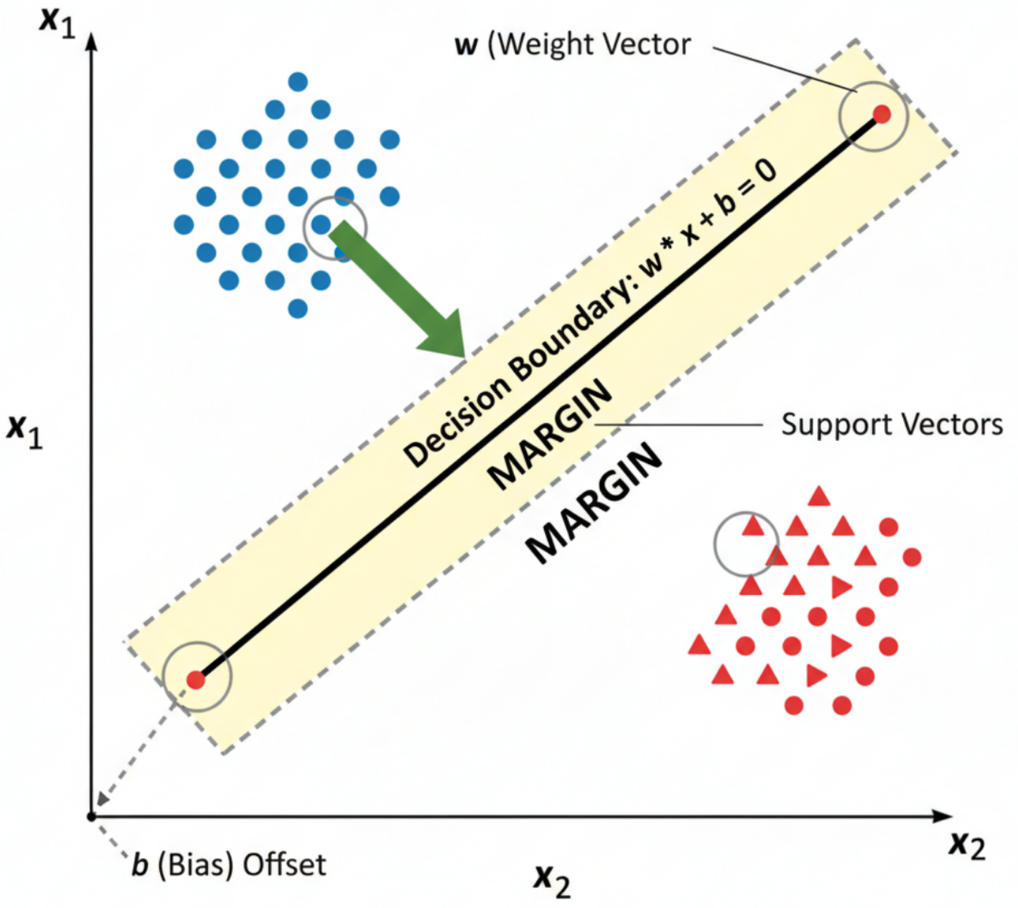

Cas linéaire séparable

Probléme Primal

Le problème primal est la première façon de définir ce défi. Vous décidez où mettre la clôture (l'hyperplan) en ajustant deux choses :

- **w : la direction et la "force" de la clôture (un vecteur qui dit comment elle est inclinée).**
- **w0 : où elle commence (un décalage). L'idée est de rendre la clôture "aussi fine que possible" ($\min \frac{1}{2}\|w\|^2$) tout en s'assurant que tous les point sont du bon côté avec un peu d'espace (contrainte : $y_i(w \cdot x_i + b) \geq 1$).**

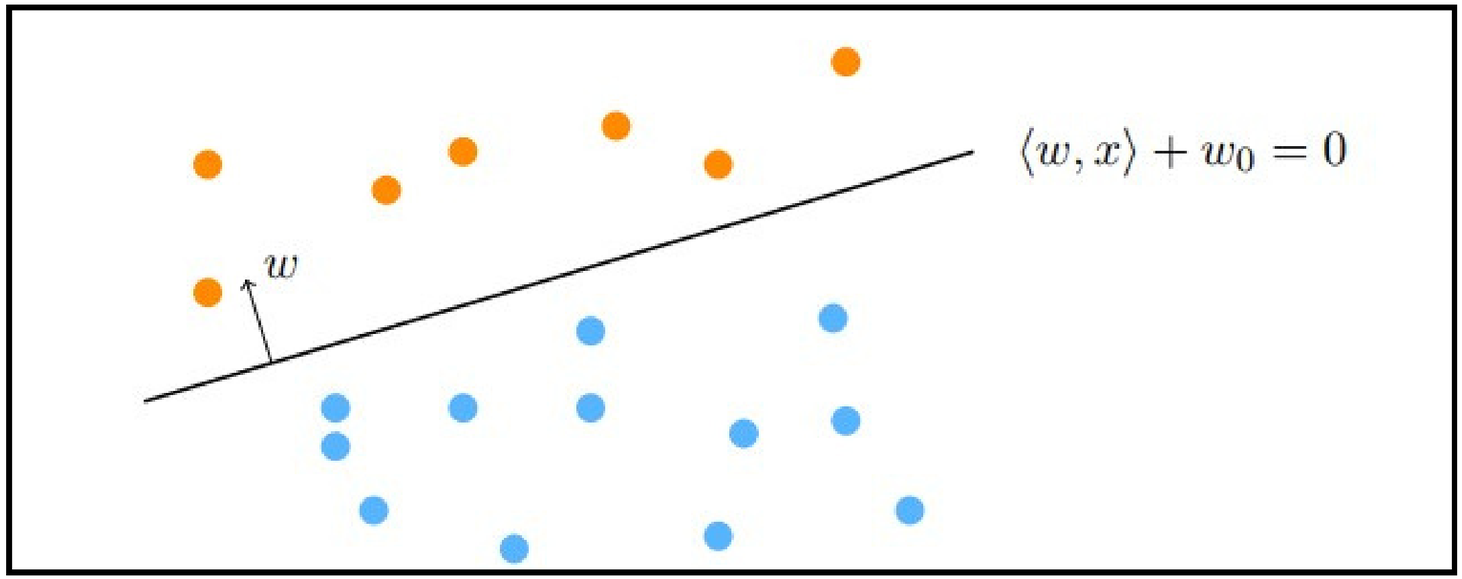

Probléme Dual

Au lieu de chercher directement w et b, on introduit de nouvelles variables appelées:

multiplicateurs de Lagrange (αi).

Ces variables représentent l'importance de chaque point d'entraînement dans la construction de la frontière.

Dans le problème dual, on cherche à maximiser une fonction qui dépend de ces αi .

Seuls les points qui se trouvent sur la marge (appelés vecteurs de support) auront un αi>0 .

Les autres points n'influencent pas la solution.

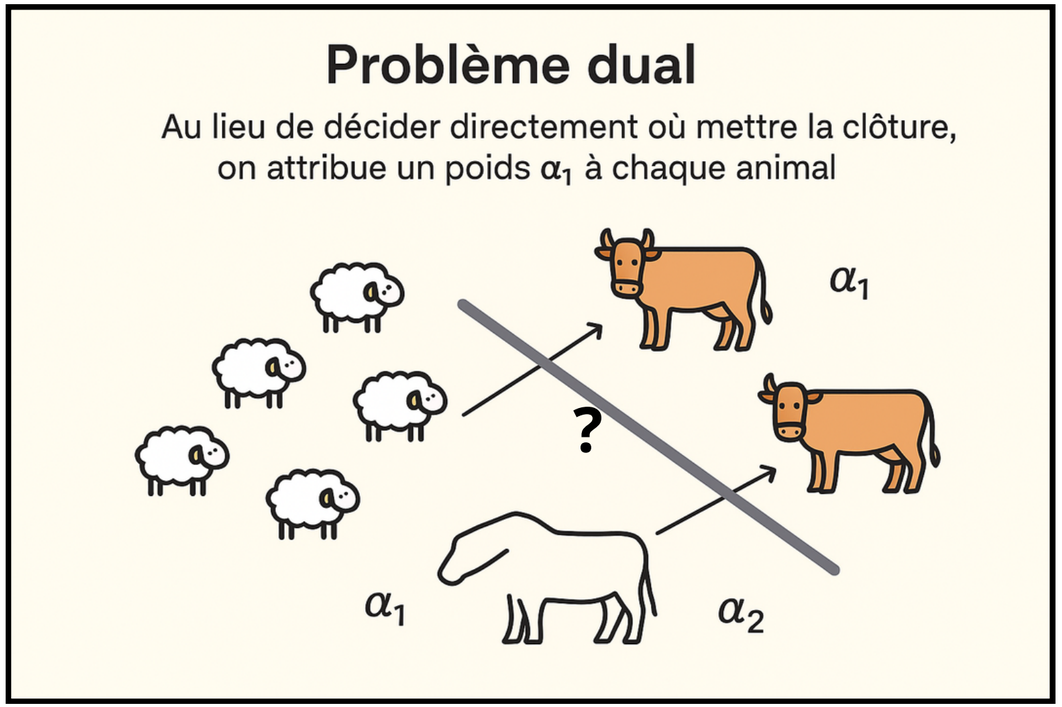

Cas linéaire non séparable

Pour des données non parfaitement séparables, on autorise certains erreurs :

On ajouter ξi≥0

Les ξi sont appelées les variables ressorts

La conrainte de mesure de confiance devient :

y.f(x) >= 1-ξi

ξi ∈ [0, 1] ⇐⇒ bien classé, mais région définie par la marge

ξi > 1 ⇐⇒ mal classé

ξi =0 ⇐⇒ bien classé

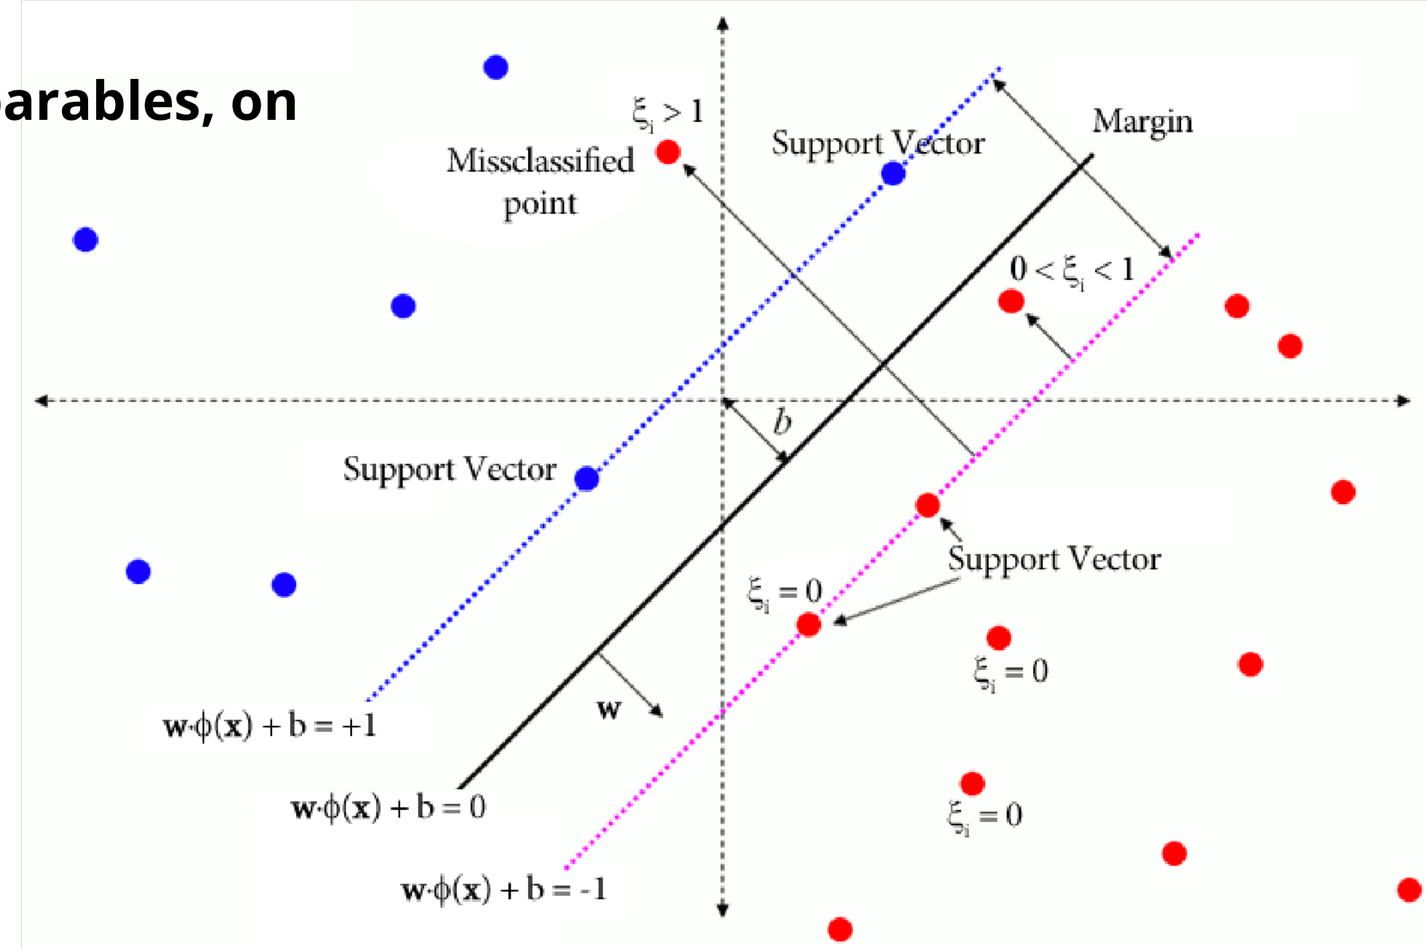

Cas linéaire non séparable

Probléme Primal ajusté :

- **Minimiser :** $\min_{w,w_0,\xi} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n}\xi_i$ **sous containte :** $y_i(w \cdot x_i + b) \geq 1$

- **ξi mesure l'erreur (combien un animal est du mauvais côté).**
- **C décide du coût de ces erreurs (grand C = peu d'erreurs tolérées).**

Vous permettez à quelques points de passer la clôture (avec une amende ξi), et C fixe le prix de cette amende.

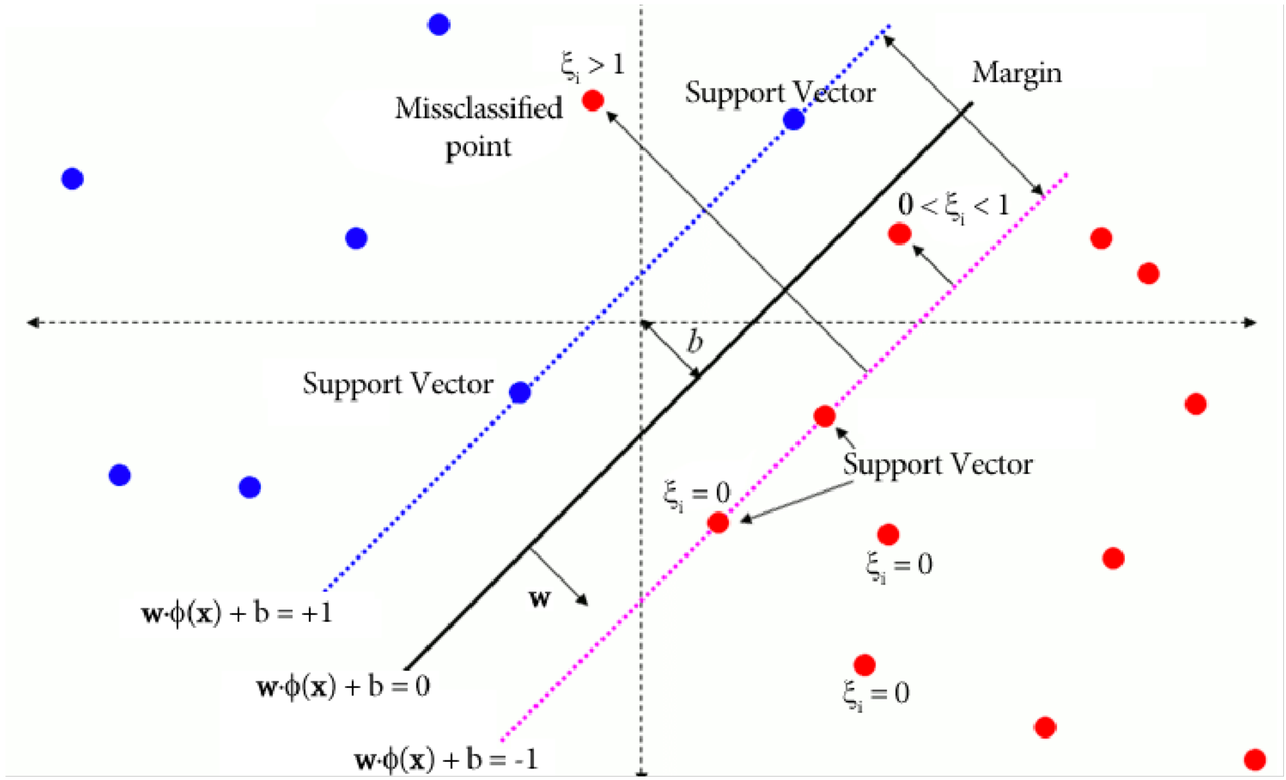

Cas non linéairement séparable

Dans ce cas , le SVM applique une **transformation** pour les projeter dans **un espace de dimension supérieure**, où une **séparation linéaire devient possible.**

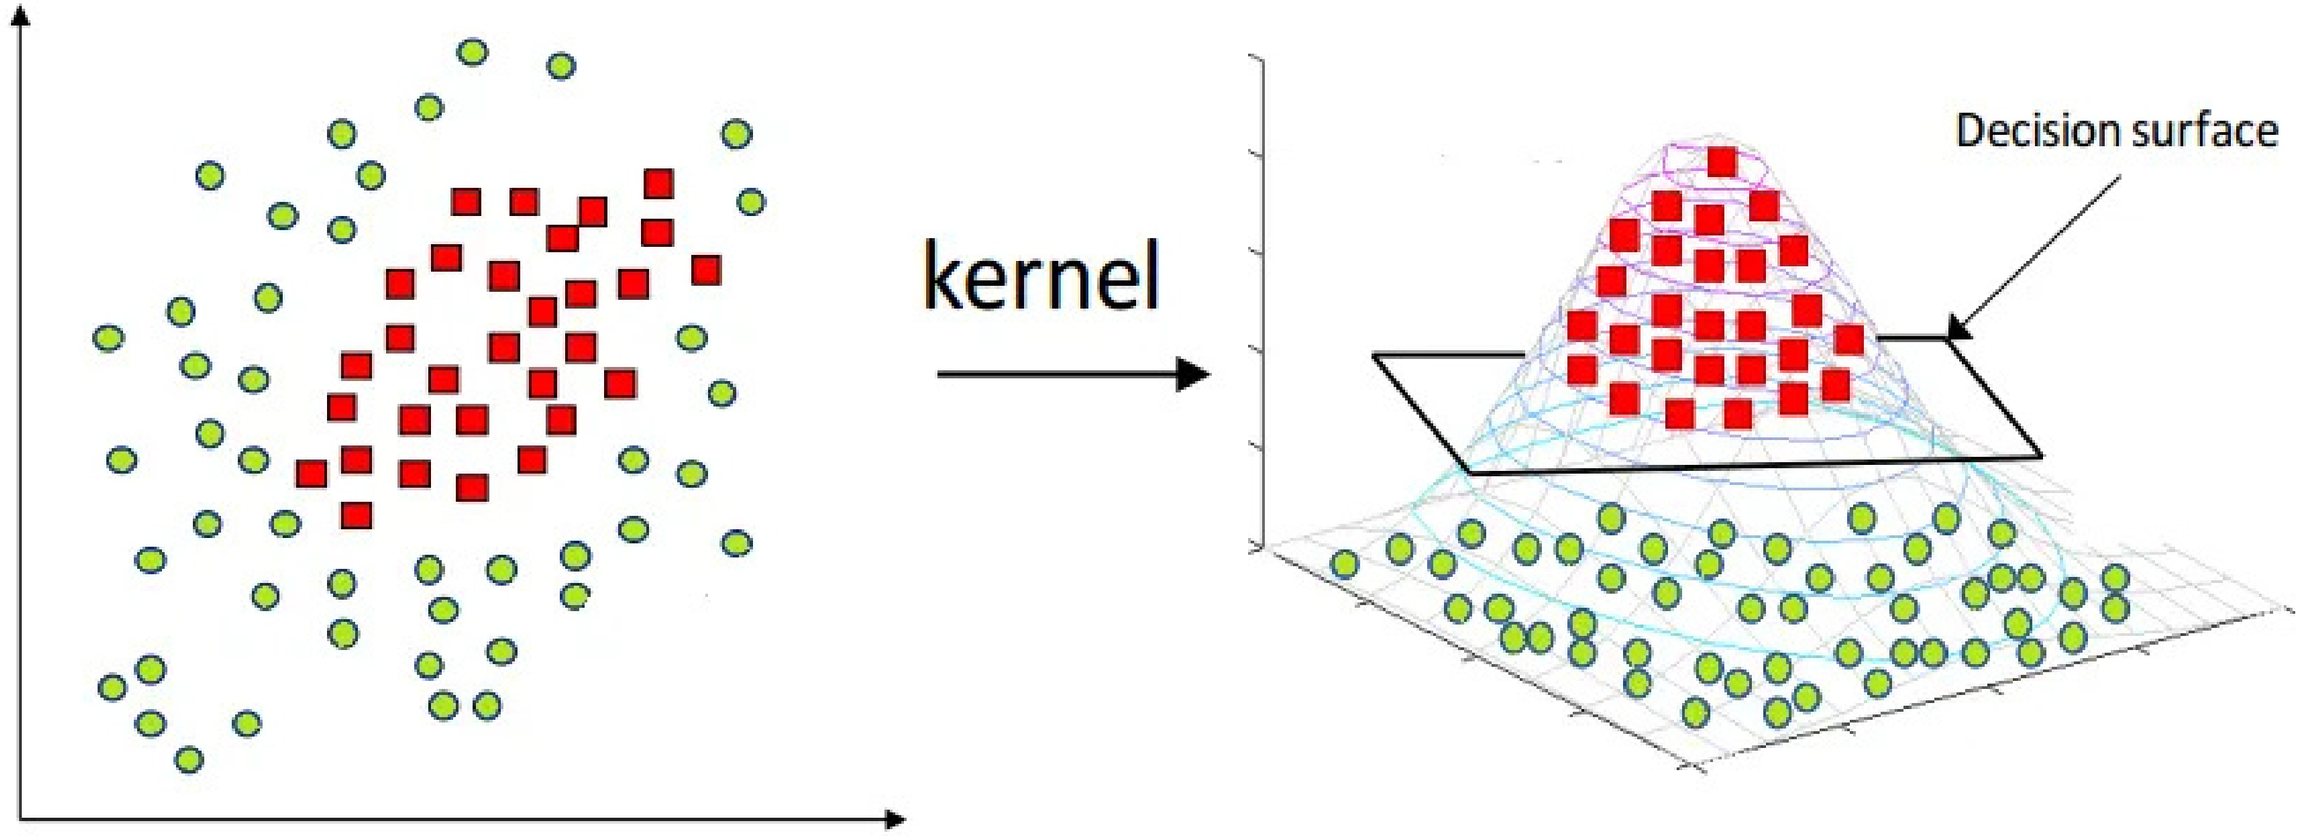

Cas non linéairement séparable

Astuce De Noyau (Kernel Trick) :

L’astuce du noyau transforme les données pour les rendre séparables, comme plier une feuille, sans faire de calculs lourds.

Puissance de Noyaux :

Flexibilité : Les noyaux permettent aux SVM de gérer des formes complexes (spirales, cercles, vagues) sans changer l’algorithme de base.

Efficacité : Pas besoin de stocker les données transformées, juste leurs similarités via le noyau

Lien avec le Problème Dual : Dans le dual (maximisation avec αi), on remplace $\langle x_i, x_j \rangle$ par $k(x_i, x_j)$. Cela signifie que l’optimisation se fait dans cet espace transformé sans jamais le calculer explicitement.

Exemples de Noyaux

Noyau linéaire :

Formule :

$$k(\boldsymbol{x}, \boldsymbol{x}') = \boldsymbol{x} \cdot \boldsymbol{x}'$$

Quand l'utiliser:

- Si les données sont presque linéairement séparables dans l'espace original.
- Rapide à calculer.

Limitation:

Ne fonctionne pas pour des données fortement non linéaires.

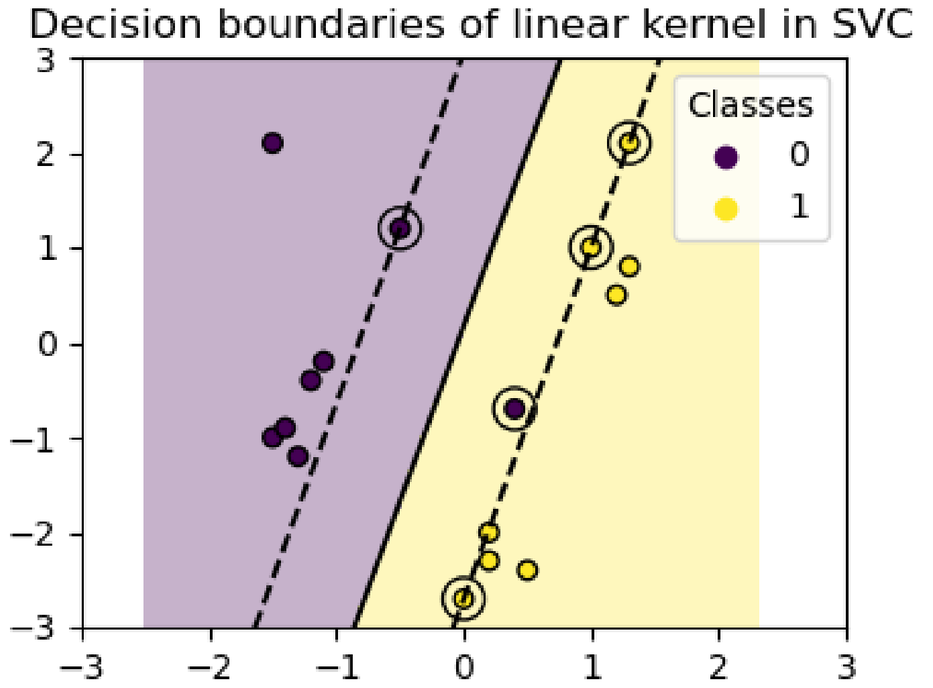

Exemples de Noyaux

Noyau polynomial :

Formule :

$$K(x_i, x_j) = (\gamma\, x_i \cdot x_j + r)^d$$

d : complexité de la courbe de séparation.
y : force de l'influence de chaque point.
r : translation de la frontière.

Quand l'utiliser:

- Quand la séparation suit une courbure polynomiale.

Avantage :

Peut modéliser des relations non linéaires simples

Limitation

Peut devenir coûteux pour de grands degrés d.

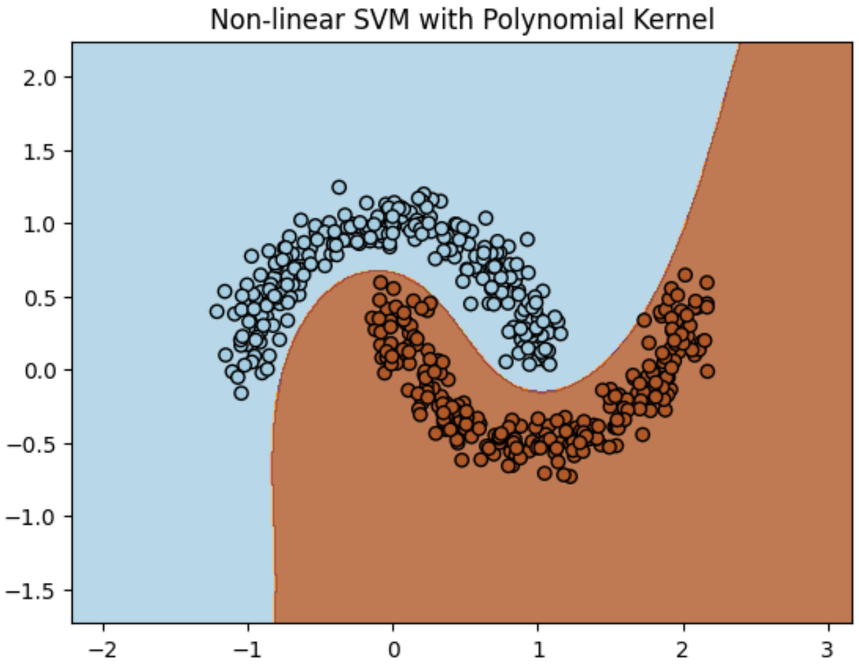

Exemples de Noyaux

Noyau RBF (Radial Basis Function / Gaussien) :

Formule :

$$k(x, x') = \exp(-\gamma \|x - x'\|^2)$$

Limitation

Besoin de régler le paramètre γ correctement pour éviter overfitting.

Quand l'utiliser:

- Pour la plupart des problèmes non linéaires classiques.
- Très flexible, fonctionne bien quand on ne connaît pas la forme de la séparation.

Avantage :

Peut séparer presque tous les types de données non linéaires.

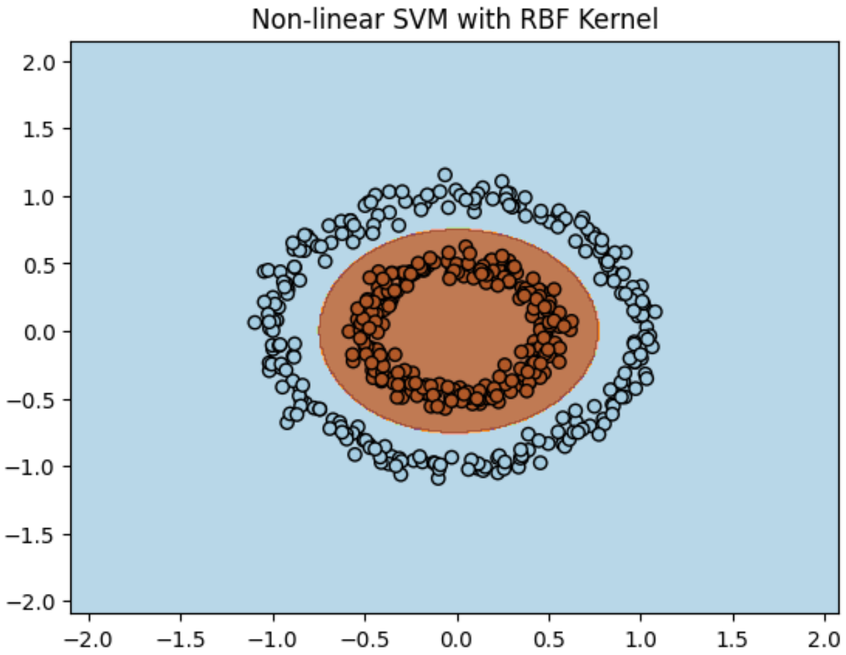

Étapes du fonctionnement du SVM

Étape	Action	Description courte
1	Représenter les données	Préparer les points avec leurs classes.
2	Choisir un type de SVM	Linéaire ou non linéaire.
3	Trouver l'hyperplan optimal	Séparer les classes avec une marge maximale.
4	Identifier les vecteurs de support	Points proches de l'hyperplan.
5	Calculer la fonction de décision	$f(x)=w \cdot x+b$ (ou sous une autre forme si on utilise un noyau).
6	Prédire de nouvelles données	Classer un nouveau point.

Avantage VS Inconvénient

Avantage : ✓

Les SVM combinent flexibilité et simplicité.

Soutenus par une base théorique solide.

Inconvénient : ✗

Moins utilisés face au deep learning.

Toujours pertinents pour des données limitées.

Conclusion et Perspectives :

le SVM est un modèle simple mais puissant, utile pour comprendre les bases de l'apprentissage automatique avant de passer à des modèles plus avancés.

Le SVM continue d'évoluer et peut être amélioré pour traiter plus de données ou travailler avec d'autres modèles d'IA modernes.

QCM

Quel est l'objectif principal des SVM ?

A) Minimiser le nombre de points utilisés
B) Ignorer les données aberrantes
C) Maximiser la marge entre les classes
D) Calculer la moyenne des données

Réponse : C

Que sont les vecteurs supports ?

A) Les points les plus proches de l'hyperplan
B) Les points les plus éloignés de l'hyperplan
C) Tous les points de la dataset
D) Les points mal classés

Réponse : A

Quel est le rôle de l'astuce du noyau ?

A) Simplifier les calculs dans l'espace original
B) Transformer les données pour les rendre séparables
C) Réduire le nombre de classes
D) Supprimer les vecteurs supports

Réponse : B

Que fait le problème primal ?

A) Dessine directement l'hyperplan avec une marge
B) Ajuste les poids des points pour l'hyperplan
C) Calcule les similarités entre points
D) Ignore la marge

Réponse : A

QCM

Pourquoi les SVM sont-ils efficaces en classification ?

A*) Parce qu'ils utilisent tous les points*
B*) Grâce à des calculs très rapides*
c*) Parce qu'ils ignorent les erreurs*
D*) Grâce à une marge large et une faible complexité*

Réponse : D

Quel est le rôle du problème dual dans les SVM ?

A*) Utiliser les vecteurs supports pour ajuster la marge*
B*) Calculer directement la position de l'hyperplan*
C*) Supprimer les données non linéaires*
D*) Ignorer les contraintes de séparation*

Réponse : A

Que permet la marge souple dans les SVM ?

A*) Séparer parfaitement toutes les données*
B*) Réduire la taille de l'hyperplan*
C*) Tolérer quelques erreurs ou chevauchements*
D*) Éliminer les vecteurs supports*

Réponse : C

Exercice

Vous êtes un data scientist et devez développer un modèle pour classer deux types de fleurs (Setosa vs Versicolor) en fonction de deux caractéristiques :

- **Longueur des pétales (cm)**
- **Largeur des pétales (cm)**

Données d'entraînement :

Fleur	Longueur	Largeur	Espèce (Classe)
1	1,5	0,2	Setosa (0)
2	1,8	0,4	Setosa (0)
3	4,5	1,5	Versicolor (1)
4	5	1,8	Versicolor (1)
5	1,2	0,1	Setosa (0)
6	4,8	1,6	Versicolor (1)

Questions :

1. **Tracez ces points sur un graphique 2D (Longueur en x, Largeur en y)**

2. **Coloriez les Setosa en bleu et les Versicolor en rouge**

3. Pouvez-vous tracer une ligne droite qui sépare parfaitement les deux classes?
4. Si oui, proposez une équation possible pour cet hyperplan(f(x) = w x +b)
5. Identifiez quels points seraient les vecteurs supports et pourquoi ?

avec :

w=(y2-y1)/(x2-x1)

partie 2:

Supposons qu'on ajoute un nouveau point :

Fleur 7: (1.5 ,0.1) - Versicolor (1)

1. La séparation est-elle toujours linéairement possible?
2. Quel noyau proposeriez-vous pour résoudre ce problème?

(Noyau linéaire ,Noyau polynomial ,Noyau RBF)

partie 3:

Vous recevez une nouvelle fleur avec :

- Longueur: 4.2 cm
- Largeur: 1.3 cm

1. À quelle classe appartiendrait cette fleur selon votre modèle et pourquoi ?

partie 4:

J’ai recherché une fleur Setosa (True) dans ce module et j’ai obtenu ce résultat:

1. **calculer le Précision et le Exactitude en utilisent tableau de confusion**

Fleur	Longueur	Largeur	résultat Réel	résultat prédit
1	0,8	0,4	Setosa (0)	setosa(0)
2	1,7	0,6	Setosa (0)	Versicolor (1)
3	4,3	1,7	Versicolor (1)	Setosa (0)
4	5,2	1,9	Versicolor (1)	Versicolor (1)
5	1,2	0,3	Setosa (0)	Setosa (0)
6	4,8	1,4	Versicolor (1)	Versicolor (1)

Merci pour votre attention